

**PENGEMBANGAN SISTEM REKOMENDASI FACULTY
SUPERVISOR UNTUK MAHASISWA MENGGUNAKAN
SEMANTIC SIMILARITY BERBASIS WEBSITE DI
UNIVERSITAS XYZ**


SKRIPSI

oleh

Muhammad Rizki Afdolli 2602139141

Rakha Naufal Azizi 2602187241

Theofilus Adhi Septian 2602096230



Computer Science Study Program

School of Computer Science

Universitas Bina Nusantara

BANDUNG

2025

**PENGEMBANGAN SISTEM REKOMENDASI FACULTY
SUPERVISOR UNTUK MAHASISWA MENGGUNAKAN
SEMANTIC SIMILARITY BERBASIS WEBSITE DI
UNIVERSITAS XYZ**

SKRIPSI


**diajukan sebagai salah satu syarat
untuk gelar kesarjanaan pada
Program Studi Teknik Informatika
Jenjang Pendidikan Strata-1**

oleh

Muhammad Rizki Afdolli 2602139141

Rakha Naufal Azizi 2602187241

Theofilus Adhi Septian 2602096230



Computer Science Study Program

School of Computer Science

Universitas Bina Nusantara

BANDUNG

2025

Pernyataan Kesiapan Skripsi untuk Ujian Pendadaran

Pernyataan Penyusunan Skripsi

Kami,

Muhammad Rizki Afdolli

Rakha Naufal Azizi

Theofilus Adhi Septian,

dengan ini menyatakan bahwa Skripsi yang berjudul:

**PENGEMBANGAN SISTEM REKOMENDASI FACULTY SUPERVISOR
UNTUK MAHASISWA MENGGUNAKAN SEMANTIC SIMILARITY
BERBASIS WEBSITE DI UNIVERSITAS XYZ
*DEVELOPMENT OF A FACULTY SUPERVISOR RECOMMENDATION
SYSTEM FOR STUDENTS USING WEBSITE-BASED SEMANTIC
SIMILARITY AT XYZ UNIVERSITY***

adalah benar hasil karya kami dan belum pernah diajukan sebagai karya ilmiah, sebagian atau seluruhnya, atas nama kami atau pihak lain

Muhammad Rizki Afdolli Theofilus Adhi Septian
2602139141 **2602096230**

Rakha Naufal Azizi
2602187241

Disetujui oleh Pembimbing

Saya setuju Skripsi tersebut layak diajukan untuk Ujian Pendadaran

Budi Juarto, S.T., M.KomD6670
D6670

Bandung, 13 Juni 2026

**PENGEMBANGAN SISTEM REKOMENDASI FACULTY SUPERVISOR
UNTUK MAHASISWA MENGGUNAKAN SEMANTIC SIMILARITY
BERBASIS WEBSITE DI UNIVERSITAS XYZ**

SKRIPSI

Disusun oleh

Muhammad Rizki Afdolli
2602139141

Rakha Naufal Azizi
2602187241

Theofilus Adhi Septian
2602096230

Disetujui oleh:

Pembimbing dan Head of Study Program

Budi Juarto, S.T., M.KomD6670
D6670

Prof. Dr. Ir. Derwin Suhartono, S.Kom., MTI
Head of Computer Science Study Program

PERNYATAAN

Dengan ini saya,

Nama : Muhammad Rizki Afdolli

NIM : 2602139141

Judul Skripsi : PENGEMBANGAN SISTEM REKOMENDASI FACULTY SUPERVISOR UN

Memberikan kepada Universitas Bina Nusantara hak non-eksklusif untuk menyimpan, memperbanyak, dan menyebarkan Skripsi karya saya, secara keseluruhan atau hanya sebagian atau hanya ringkasannya saja, dalam bentuk format tercetak dan atau elektronik.

Menyatakan bahwa saya, akan mempertahankan **hak eksklusif** saya, untuk menggunakan seluruh atau sebagian isi Skripsi saya, guna pengembangan karya di masa depan, misalnya bentuk artikel, buku, perangkat lunak, ataupun sistem informasi.

Jakarta, 13 Juni 2026,

Hormat Saya,

Diketahui oleh

Muhammad Rizki Afdolli

NIM.00000

Budi Juarto, S.T., M.KomD6670

D6408

KATA PENGANTAR

Puji syukur kepada Tuhan Yang Maha Esa dengan selesainya XXX dengan judul PENGEMBANGAN SISTEM REKOMENDASI FACULTY SUPERVISOR UNTUK MAHASISWA MENGGUNAKAN SEMANTIC SIMILARITY BERBASIS WEBSITE DI UNIVERSITAS XYZ. Penulis mengucapkan terima kasih yang sedalam-dalamnya kepada berbagai pihak yang telah memberikan masukan, bimbingan, arahan, dan semangat dalam mengerjakan XXX ini, yaitu kepada:

1. Ibu Dr. Nelly, S.Kom., M.M., CSA. selaku Rektor Universitas Bina Nusantara Periode 2023 – 2028.
2. xxx selaku Direktur BINUS Bandung.
3. xxx selaku Head of Department of Computer Science, Universitas Bina Nusantara.
4. Lorem ipsum dolor sit amet, consectetur adipiscing elit.
5. Pihak lain yang tidak dapat disebutkan satu persatu.

Akhir kata, kiranya segala bimbingan, saran, dan masukan dari Bapak/Ibu yang telah diberikan kepada penulis, akan mendapat berkah dari Tuhan Yang Maha Esa.

Jakarta, 13 Juni 2026

Muhammad Rizki Afdolli

UNIVERSITAS BINA NUSANTARA

Computer Science Study Program

School of Computer Science

Skripsi Sarjana Teknik Informatika

**PENGEMBANGAN SISTEM REKOMENDASI FACULTY SUPERVISOR
UNTUK MAHASISWA MENGGUNAKAN SEMANTIC SIMILARITY
BERBASIS WEBSITE DI UNIVERSITAS XYZ**

Muhammad Rizki Afdolli- 2602139141

Rakha Naufal Azizi- 2602187241

Theofilus Adhi Septian- 2602096230

ABSTRACT

The manual process of mapping students to internship supervisors in the Enrichment Program at XYZ University often leads to inefficiencies, inconsistent assignments, and mismatches between student interests and supervisor expertise. This research aims to develop an internship supervisor recommendation system using semantic similarity to support the supervisor assignment process in the Enrichment Program at XYZ University. The proposed system functions as a decision support system, providing ranked supervisor recommendations while preserving final decision-making authority for the Enrichment Program Coordinator (EPC).

The system utilizes textual data from student profiles and supervisor expertise descriptions, which are processed using natural language processing techniques to compute semantic similarity scores. To enhance assignment quality, similarity-based scoring is complemented with a company group bonus that encourages consistent placement of students from the same company, followed by a greedy capacity-constrained allocation algorithm to respect supervisor workload limits. System evaluation is conducted by comparing the generated recommendations with ground truth data obtained from manual matching performed by multiple EPCs and historical supervisor assignment data from the past year.

This research results in a functional prototype system consisting of a user interface and a simple backend implementation. The evaluation results indicate that the proposed system is capable of producing recommendations that align closely with established manual mapping practices, while offering improved efficiency, consistency, and transparency in the internship supervisor assignment process. This study demonstrates the potential of semantic similarity combined with company-aware scoring as an effective solution for supporting academic administrative processes in higher education institutions.

Keywords: *Supervisor Recommendation System, Semantic Similarity, Company Group Bonus, Natural Language Processing, Decision Support System, Internship Program.*

ABSTRAK

Proses pemetaan mahasiswa ke Faculty Supervisor magang dalam Program Enrichment di XYZ University hingga saat ini masih banyak dilakukan secara manual, sehingga berpotensi menimbulkan ketidakefisienan, ketidakkonsistenan, serta ketidaksesuaian antara minat mahasiswa dan bidang keahlian Faculty Supervisor. Penelitian ini bertujuan untuk mengembangkan sistem rekomendasi Faculty Supervisor magang menggunakan pendekatan semantic similarity sebagai pendukung proses penentuan pembimbing pada Program Enrichment di XYZ University. Sistem yang dikembangkan berperan sebagai decision support system dengan memberikan rekomendasi Faculty Supervisor dalam bentuk peringkat, sementara keputusan akhir tetap berada pada Enrichment Program Coordinator (EPC).

Sistem memanfaatkan data tekstual dari profil mahasiswa dan deskripsi bidang keahlian Faculty Supervisor yang diproses menggunakan teknik natural language processing untuk menghitung tingkat kemiripan semantik. Untuk meningkatkan kualitas penugasan, perhitungan kemiripan dilengkapi dengan company group bonus yang mendorong konsistensi penempatan mahasiswa dari perusahaan yang sama, diikuti oleh algoritma alokasi greedy berbasis kapasitas untuk memastikan pemerataan beban bimbingan. Evaluasi sistem dilakukan dengan membandingkan hasil rekomendasi yang dihasilkan dengan ground truth yang diperoleh dari pencocokan

manual oleh beberapa EPC serta data pemetaan historis dalam rentang waktu satu tahun terakhir.

Penelitian ini menghasilkan sebuah prototipe sistem yang mencakup antarmuka pengguna dan backend. Hasil evaluasi menunjukkan bahwa sistem rekomendasi yang dikembangkan mampu menghasilkan rekomendasi yang selaras dengan praktik pemetaan manual yang telah diterapkan, serta berpotensi meningkatkan efisiensi, konsistensi, dan transparansi dalam proses penentuan Faculty Supervisor magang. Penelitian ini menunjukkan bahwa pendekatan semantic similarity yang dikombinasikan dengan company-aware scoring dapat menjadi solusi pendukung yang efektif dalam proses administrasi akademik di perguruan tinggi.

Keywords: *Sistem Rekomendasi Faculty Supervisor, Semantic Similarity, Company Group Bonus, Natural Language Processing, Decision Support System, Program Enrichment*

DAFTAR ISI

Kata Pengantar	vii
Abstrak	viii
Daftar Isi	xv
Daftar Gambar	xvi
Daftar Tabel	xviii
 I PENDAHULUAN	 1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Ruang Lingkup Penelitian	4
1.4 Tujuan dan Manfaat	4
1.4.1 Tujuan	4
1.4.2 Manfaat	5
1.5 Metode Penelitian	5
1.5.1 Pengumpulan Data	6
1.5.2 Praposes Data	6
1.5.3 Pengembangan Sistem Rekomendasi	6
1.5.4 Pengembangan Prototipe Sistem	7
1.5.5 Evaluasi Sistem	7
1.6 Sistematika Penulisan	7
 II TINJAUAN PUSTAKA	 9
2.1 Landasan Teori	9
2.1.1 Sistem Rekomendasi	9
2.1.2 Artificial Intelligence	9
2.1.3 Machine Learning	10
2.1.4 Deep Learning	10
2.1.5 Natural Language Processing	10

2.1.6	Text Mining	11
2.1.7	Text Preprocessing	11
2.1.8	Representasi Teks	12
2.1.9	TF-IDF	12
2.1.10	Word Embedding	13
2.1.11	Transformer-Based Embedding	14
2.1.12	Bert Embedding	14
2.1.13	Semantic Similarity	15
2.1.14	Cosine Similarity	15
2.1.15	Text Embedding & Model Embedding	16
2.1.16	BGE-M3 (BAAI/bge-m3)	16
2.1.17	Qwen3-Embedding-0.6B	17
2.1.18	Multilingual E5-Large-Instruct (intfloat/multilingual-e5- large-instruct)	17
2.1.19	Evaluasi Sistem Rekomendasi	17
2.1.20	Hit@K	18
2.1.21	Normalized Discounted Cumulative Gain (nDCG@K)	18
2.1.22	Recall@K	19
2.1.23	Precision@K	19
2.1.24	Mean Reciprocal Rank (MRR)	19
2.1.25	Cosine Similarity Score	20
2.1.26	Assignment match rate	20
2.1.27	Teknologi Pendukung Sistem	21
2.1.28	Python	21
2.1.29	JavaScript	21
2.1.30	Flask + Jinja2	22
2.1.31	Pytorch	22
2.1.32	SQLite	23
2.1.33	SQLAlchemy	23
2.1.34	Sentence-Transformers	24
2.1.35	Post Forwarding	24

2.1.36	On-Premises Deployment	24
2.1.37	Unified Modeling Language	25
2.1.38	Usecase Diagram	25
2.1.39	Activity Diagram	26
2.1.40	Class Diagram	26
2.1.41	Entity Relationship Diagram	26
2.2	Penelitian Terkait	27
III METODE PENELITIAN		31
3.1	Kerangka Berpikir	31
3.2	Metodologi Penelitian	33
3.2.1	Analisis	33
3.2.2	Analisis Permasalahan	33
3.2.3	Analisis Permasalahan	34
3.2.4	Analisis Kebutuhan Sistem	34
3.2.5	Kebutuhan Fungsional	34
3.2.6	Kebutuhan Non-Fungsional	35
3.2.7	Analisis Data	36
3.2.8	Perencanaan	37
3.2.9	Perancangan Model Rekomendasi Berbasis Semantic Simi- larity	38
3.2.10	Konsep Dasar Model Rekomendasi	38
3.2.11	Pembentukan Representasi Data Faculty Supervisor	38
3.2.12	Pemrosesan Data Mahasiswa	41
3.2.13	Alur Pemrosesan Data	42
3.2.14	Kandidat Model Text Embedding	43
3.2.15	Qwen3-Embedding-0.6B	44
3.2.16	BAAI/bge-m3	44
3.2.17	intfloat/multilingual-e5-large-instruct	44
3.2.18	Keterkaitan Kandidat Model dengan Mekanisme Rekomendasi	45

3.2.19	Mekanisme Perhitungan dan Perangkingan Rekomendasi . .	45
3.2.20	Validasi Slot Bimbingan faculty supervisor	47
3.2.21	Strategi evaluasi	48
3.2.22	Perancangan UML	49
3.2.23	Use Case Diagram	49
3.2.24	Use Case Narative	50
3.2.25	Activity Diagram	70
3.2.26	Class diagram	78
3.2.27	Entity Relationship Diagram	80
3.2.28	Tahapan Implementasi	81
3.2.29	Implementasi Pengolahan Data	82
3.2.30	Implementasi Praproses Data	82
3.2.31	Implementasi Representasi Teks	83
3.2.32	Implementasi Perhitungan Semantic Similarity	83
3.2.33	Implementasi Sistem Rekomendasi	83
3.2.34	Implementasi dan Deployment Sistem	84
IV	HASIL DAN PEMBAHASAN	85
4.1	Testing Environment	85
4.2	Hasil	86
4.2.1	Evaluasi Model	86
4.2.2	Hasil Analisis Model dan Pemilihan Model Akhir	88
4.2.3	Analisis Pengaruh Parameter Konfigurasi	89
4.2.3.1	Pengaruh Parameter <code>extra_docs</code>	89
4.2.3.2	Pengaruh Parameter <code>group_bonus</code>	90
4.2.3.3	Konfigurasi Terbaik	91
4.2.4	Distribusi Beban Pembimbing	91
4.2.5	Distribusi Peringkat Penugasan	92
4.2.6	Aplikasi Web	93
4.2.6.1	Login Page	93
4.2.6.2	Register Page	94

4.2.6.3	Dashboard	94
4.2.6.4	Data Center	95
4.2.6.5	Run History	95
4.2.6.6	Run Details	96
4.2.6.7	Supervisor Studio	96
4.2.6.8	Rules Studio	97
4.3	Evaluasi	97
4.3.1	Login Page	98
4.3.2	Register Page	98
4.3.3	Dashboard	99
4.3.4	Data Center	101
4.3.5	Generate New Run	101
4.3.6	Run History	102
4.3.7	Supervisor Studio	103
4.3.8	Rules Studio	104
V	SIMPULAN DAN SARAN	106
5.1	Simpulan	106
5.2	Saran	107
	LAMPIRAN	113
	Lampiran A: Hasil Eksperimen 1	113

DAFTAR GAMBAR

1.1	Pertumbuhan Jumlah Mahasiswa XYZ University Tahun 2021–2024	2
3.1	Alur Kerangka Berpikir	31
3.2	Use Case Diagram Sistem Rekomendasi Faculty Supervisor	50
3.3	Activity Diagram Login	70
3.4	Activity Diagram Register	71
3.5	Activity Diagram Import Data Mahasiswa	72
3.6	Activity Diagram Kelola Data Faculty Supervisor	73
3.7	Activity Diagram Kelola Keywords Supervisor	74
3.8	Activity Diagram Trigger Proses Rekomendasi	75
3.9	Activity Diagram Lihat Hasil Rekomendasi	76
3.10	Activity Diagram Export Hasil ke Excel	77
3.13	Class Diagram: Service Architecture	78
3.11	Class Diagram: ORM Models (<u>id</u> = PK, <i>italic</i> = FK)	79
3.12	Class Diagram: Runtime Dataclasses	80
3.14	Entity Relationship Diagram (<u>id</u> = PK, <i>italic</i> = FK)	81
4.1	Tampilan Halaman Login	93
4.2	Tampilan Halaman Register	94
4.3	Tampilan Halaman Dashboard	94
4.4	Tampilan Halaman Data Center	95
4.5	Tampilan Halaman Run History	95
4.6	Tampilan Halaman Run Details	96
4.7	Tampilan Halaman Supervisor Studio	96
4.8	Tampilan Halaman Rules Studio	97

DAFTAR TABEL

2.1	Tabel Penelitian Terkait	29
3.1	Tabel 3. Analisis Kebutuhan Fungsional	35
3.2	Tabel 3. Analisis Kebutuhan Non-Fungsional	36
3.3	Tabel 3. Representasi Data Faculty Supervisor	39
3.4	Tabel 3. Pemrosesan Data Mahasiswa	41
3.5	Tabel 3. Struktur Data Knowledge Base	46
3.6	Tabel 3.6 Use Case Register	51
3.7	Tabel 3.7 Use Case Login	52
3.8	Tabel 3.8 Use Case Import Data Mahasiswa	53
3.9	Tabel 3.9 Use Case Kelola Data Faculty Supervisor	55
3.10	Tabel 3.10 Use Case Kelola Keywords Supervisor	56
3.11	Tabel 3.11 Use Case Trigger Proses Rekomendasi	58
3.12	Tabel 3.12 Use Case Lihat Riwayat Run	61
3.13	Tabel 3.13 Use Case Lihat Hasil Rekomendasi	62
3.14	Tabel 3.14 Use Case Export Hasil ke Excel	64
3.15	Tabel 3.15 Use Case Logout	66
3.16	Tabel 3.16 Use Case Lihat Dashboard	67
4.1	Spesifikasi Perangkat Keras	85
4.2	Spesifikasi Perangkat Lunak	86
4.3	Perbandingan Metrik Evaluasi Antar Model	87
4.4	Rata-rata Skor Kemiripan Antar Model	88
4.5	Pengaruh Parameter <code>extra_docs</code> terhadap <code>%Rank-1</code>	90
4.6	Pengaruh Parameter <code>group_bonus</code> terhadap <code>%Rank-1</code>	90
4.7	Metrik Konfigurasi Terbaik (Run 8: <code>bge-m3</code> , <code>extra_docs=True</code> , <code>group_bonus=False</code>)	91

4.8	Distribusi Beban Penugasan Pembimbing (identik pada seluruh 18 konfigurasi)	91
4.9	Distribusi Peringkat Penugasan (<i>Pooled</i> , 3.078 slot dari 18 konfigurasi)	92
4.10	Skenario Login Page	98
4.11	Skenario Register Page	99
4.12	Skenario Dashboard	100
4.13	Skenario Data Center	101
4.14	Skenario Generate New Run	102
4.15	Skenario Run History	103
4.16	Skenario Supervisor Studio	104
4.17	Skenario Rules Studio	105

BAB I

PENDAHULUAN

1.1 Latar Belakang


Program Enrichment merupakan salah satu komponen penting dalam kurikulum Universitas XYZ yang bertujuan untuk membekali mahasiswa dengan pengalaman pembelajaran berbasis praktik, seperti magang industri, riset, kewirausahaan, dan pengembangan profesional lainnya BINUS University (2025). Dalam pelaksanaan Program Enrichment, mahasiswa didampingi oleh Faculty Supervisor yang berperan dalam memberikan arahan akademik, monitoring, serta evaluasi selama periode program berlangsung.

Peran Faculty Supervisor dalam Program Enrichment sangat krusial karena kualitas pendampingan yang diberikan dapat memengaruhi capaian pembelajaran mahasiswa. Oleh karena itu, kesesuaian antara mahasiswa dan Faculty Supervisor, khususnya dari sisi bidang keahlian dan minat, menjadi faktor penting dalam menunjang keberhasilan program ini.

Namun, Berdasarkan hasil observasi dan wawancara terstruktur yang dilakukan kepada Enrichment Program Coordinator (EPC) dari dua fakultas di XYZ University, diketahui bahwa proses pemetaan mahasiswa ke Faculty Supervisor saat ini masih dilakukan secara manual menggunakan spreadsheet. Proses ini membutuhkan waktu satu hingga tiga minggu per batch dengan jumlah mahasiswa yang dapat mencapai ratusan orang, serta rentan terhadap kesalahan yang memerlukan revisi berulang hingga dua puluh kali per batch. Penentuan Faculty Supervisor umumnya dilakukan secara acak tanpa mempertimbangkan kesesuaian bidang keahlian, sehingga mahasiswa berpotensi mendapatkan pembimbing yang tidak relevan dengan topik atau minat program enrichment-nya.

Hasil survei menunjukkan bahwa proses pemetaan manual ini menimbulkan berbagai permasalahan, antara lain beban pembimbing antar dosen yang belum merata, mahasiswa mendapatkan Faculty Supervisor di luar bidang minat atau keah-

liannya, serta lamanya waktu yang dibutuhkan untuk menyelesaikan proses pemetaan satu batch mahasiswa yang dapat mencapai satu hingga tiga minggu. Selain itu, kesalahan dan revisi pemetaan masih sering terjadi, sehingga EPC perlu melakukan perbaikan data secara berulang melalui pengeditan manual. Kondisi tersebut meningkatkan beban kerja EPC dan berpotensi menurunkan efisiensi serta transparansi proses penentuan Faculty Supervisor.



Gambar 1.1. Pertumbuhan Jumlah Mahasiswa XYZ University Tahun 2021–2024

Seiring dengan meningkatnya jumlah mahasiswa di XYZ University dari tahun ke tahun sebagaimana terlihat pada Gambar 1.1, serta meningkatnya jumlah mahasiswa yang mengikuti Program Enrichment dan kompleksitas data yang harus dipertimbangkan, pendekatan manual menjadi semakin tidak efektif. Oleh karena itu, diperlukan suatu sistem yang dapat membantu proses pemetaan Faculty Supervisor secara lebih efisien, objektif, dan terukur. Salah satu pendekatan yang dapat digunakan adalah sistem rekomendasi berbasis semantic similarity, yang memungkinkan pengukuran tingkat kesesuaian antara profil mahasiswa dan bidang keahlian dosen berdasarkan kemiripan makna dari data tekstual yang dimiliki.

Beberapa penelitian sebelumnya telah mengeksplorasi otomatisasi proses alokasi pembimbing akademik. Fan et al. (2021) menunjukkan bahwa pendekatan otomatis berbasis machine learning memiliki potensi signifikan dalam mengatasi keterbatasan proses manual, khususnya pada institusi dengan jumlah mahasiswa yang besar. Dalam konteks yang lebih dekat, Rismanto et al. (2020) mengembangkan

sistem rekomendasi dosen pembimbing tugas akhir berbasis pembobotan TF-IDF dan cosine similarity yang mencapai akurasi rata-rata 75% dibandingkan data aktual. Namun, pendekatan berbasis TF-IDF masih bergantung pada pencocokan kata kunci secara leksikal, sehingga belum mampu menangkap kemiripan makna secara kontekstual apabila mahasiswa dan dosen menggunakan terminologi yang berbeda untuk topik yang serupa. Oleh karena itu, penelitian ini mengusulkan pendekatan berbasis semantic similarity menggunakan model embedding, yang memungkinkan pengukuran kesesuaian antara profil mahasiswa dan bidang keahlian Faculty Supervisor berdasarkan makna teks secara lebih mendalam.

Untuk memastikan kualitas rekomendasi yang dihasilkan, diperlukan evaluasi terhadap sistem dengan membandingkan hasil rekomendasi otomatis dengan ground truth. Ground truth pada penelitian ini diperoleh berdasarkan hasil pencocokan manual yang dilakukan oleh beberapa Enrichment Program Coordinator (EPC) dari berbagai fakultas, serta didukung oleh dokumen pemetaan historis yang telah digunakan dalam periode sebelumnya. Pendekatan ini bertujuan untuk merepresentasikan praktik penentuan Faculty Supervisor yang telah diterapkan dan diterima secara institusional.

Sistem rekomendasi yang dikembangkan dalam penelitian ini berperan sebagai decision support system yang memberikan rekomendasi kepada EPC, tanpa menggantikan keputusan akhir yang tetap berada pada EPC. Penelitian ini berfokus pada pengembangan sebuah prototipe sistem yang mencakup antarmuka pengguna dan backend sederhana sebagai implementasi dari metode yang diusulkan. Dengan demikian, diharapkan sistem yang dikembangkan dapat membantu meningkatkan efisiensi, akurasi, serta transparansi dalam proses pemetaan Faculty Supervisor Program Enrichment di XYZ University.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang dan mengembangkan sistem rekomendasi Faculty Su-

pervisor magang berbasis semantic similarity?

2. Seberapa tinggi tingkat kesesuaian hasil rekomendasi sistem dengan ground truth yang diperoleh dari pencocokan manual oleh EPC?
3. Bagaimana sistem rekomendasi yang dikembangkan dapat membantu meningkatkan efisiensi proses pemetaan Faculty Supervisor?

1.3 Ruang Lingkup Penelitian

Agar penelitian ini lebih terarah, ruang lingkup penelitian dibatasi pada:

1. Penelitian difokuskan pada pemetaan Faculty Supervisor magang dalam Program Enrichment di XYZ University .
2. Sistem rekomendasi dikembangkan menggunakan pendekatan semantic similarity berbasis data tekstual.
3. Evaluasi sistem dilakukan dengan membandingkan hasil rekomendasi dengan ground truth yang diperoleh dari pencocokan manual dan data pemetaan historis.
4. Penelitian menghasilkan sebuah prototipe sistem yang mencakup antarmuka pengguna dan backend.
5. Penelitian ini tidak membahas kebijakan akademik di luar proses pemetaan Faculty Supervisor.

1.4 Tujuan dan Manfaat

1.4.1 Tujuan

Tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis permasalahan dalam proses pemetaan Faculty Supervisor Program Enrichment yang dilakukan secara manual.

2. Mengembangkan sistem rekomendasi Faculty Supervisor magang menggunakan pendekatan semantic similarity.
3. Melakukan evaluasi hasil rekomendasi sistem menggunakan ground truth berdasarkan pencocokan manual.
4. Menghasilkan prototipe sistem sebagai pendukung EPC dalam proses penentuan Faculty Supervisor secara lebih efektif dan terstruktur.

1.4.2 Manfaat

Adapun manfaat yang diharapkan dari pengembangan sistem ini adalah:

1. Membantu EPC dalam mempercepat dan mempermudah proses pemetaan mahasiswa ke Faculty Supervisor.
2. Mengurangi kesalahan dan revisi pemetaan yang disebabkan oleh proses manual.
3. Meningkatkan kesesuaian antara minat mahasiswa dan bidang keahlian Faculty Supervisor.
4. Menjadi dasar pengembangan sistem pemetaan Faculty Supervisor yang lebih terintegrasi di masa depan.

1.5 Metode Penelitian

Metode penelitian yang digunakan dalam penelitian ini disusun untuk mendukung pengembangan sistem rekomendasi Faculty Supervisor magang pada Program Enrichment XYZ University. Penelitian ini menggunakan pendekatan rekayasa perangkat lunak dengan pemanfaatan metode semantic similarity sebagai dasar sistem rekomendasi, serta evaluasi hasil rekomendasi menggunakan ground truth berdasarkan pencocokan manual.

Tahapan metode penelitian secara umum meliputi studi pustaka, pengumpulan data, praproses data, pengembangan sistem rekomendasi, evaluasi sistem, serta pengembangan prototipe sistem.

1.5.1 Pengumpulan Data

Pengumpulan data dilakukan melalui studi dokumen dan data institusional yang digunakan dalam proses pemetaan Faculty Supervisor Program Enrichment. Data yang digunakan dalam penelitian ini meliputi data Faculty Supervisor, data mahasiswa peserta Program Enrichment, serta dokumen pemetaan historis Faculty Supervisor dan mahasiswa dalam rentang waktu satu tahun terakhir di XYZ University, khususnya XYZ. Selain itu, data ground truth diperoleh dari hasil pencocokan manual yang dilakukan oleh beberapa Enrichment Program Coordinator (EPC) dari berbagai fakultas.

1.5.2 Praposes Data

Sebelum data digunakan dalam sistem rekomendasi, dilakukan tahapan praproses data untuk memastikan kualitas dan konsistensi data tekstual. Tahapan praproses meliputi pembersihan data dari informasi yang tidak relevan, normalisasi teks, tokenisasi, serta penghapusan kata-kata umum (stop words) yang tidak memiliki makna signifikan. Tahapan ini bertujuan untuk mempersiapkan data agar dapat diproses secara optimal dalam perhitungan kemiripan semantik.

1.5.3 Pengembangan Sistem Rekomendasi

Pada tahap ini dilakukan pengembangan sistem rekomendasi Faculty Supervisor menggunakan pendekatan semantic similarity. Sistem dirancang untuk menghitung tingkat kemiripan antara profil mahasiswa dan bidang keahlian dosen berdasarkan representasi data tekstual. Hasil perhitungan kemiripan digunakan untuk menghasilkan peringkat rekomendasi Faculty Supervisor bagi setiap mahasiswa.

Selain perhitungan kemiripan semantik, sistem juga mendukung penerapan aturan pendukung, seperti batasan kuota Faculty Supervisor, untuk membantu pemerataan beban pembimbing. Sistem yang dikembangkan bersifat decision support system, di mana rekomendasi yang dihasilkan digunakan sebagai bahan pertimbangan oleh EPC, tanpa menggantikan keputusan akhir.

1.5.4 Pengembangan Prototipe Sistem

Sebagai implementasi dari metode yang diusulkan, penelitian ini menghasilkan sebuah prototipe sistem yang mencakup antarmuka pengguna dan backend sederhana. Prototipe dikembangkan untuk mendemonstrasikan alur kerja sistem rekomendasi mulai dari input data, proses perhitungan kemiripan, hingga penyajian hasil rekomendasi kepada pengguna. Pengembangan prototipe ini bertujuan untuk memvalidasi penerapan metode dalam bentuk sistem yang dapat digunakan secara operasional.

1.5.5 Evaluasi Sistem

Evaluasi sistem dilakukan dengan membandingkan hasil rekomendasi yang dihasilkan oleh sistem dengan ground truth yang diperoleh dari pencocokan manual dan data pemetaan historis. Evaluasi ini bertujuan untuk menilai tingkat kesesuaian dan relevansi rekomendasi sistem terhadap keputusan manual yang telah diterapkan. Hasil evaluasi digunakan untuk menganalisis kinerja sistem serta potensi peningkatan efektivitas proses pemetaan Faculty Supervisor.

1.6 Sistematika Penulisan

Skripsi ini disusun dengan sistematika penulisan yang terdiri dari lima bab dengan rincian sebagai berikut:

BAB 1 PENDAHULUAN

Pada bab ini membahas mengenai mengenai latar belakang permasalahan, hipotesis, ruang lingkup, tujuan dan manfaat, metode penelitian hingga sistematika penulisan yang digunakan.

BAB 2 TINJAUAN PUSTAKA

Pada bab ini berfokus pada pembahasan teori-teori yang berkaitan dengan sistem rekomendasi, semantic similarity, natural language processing, serta penelitian terdahulu yang relevan sebagai dasar pengembangan sistem.

BAB 3 METODE PENELITIAN

Pada bab ini memberikan penjelasan mengenai metode penelitian yang digunakan pada penelitian ini, tahapan pengembangan sistem rekomendasi, arsitektur sistem, serta perancangan alur dan komponen sistem.

BAB 4 HASIL DAN PEMBAHASAN

Pada bab ini membahas proses implementasi sistem rekomendasi, hasil pengujian sistem, serta analisis dan pembahasan hasil evaluasi yang diperoleh

BAB 5 SIMPULAN DAN SARAN

Pada bab ini membahas mengenai kesimpulan dan saran - saran yang diusulkan dari hasil penelitian yang dilakukan dalam tugas akhir agar dapat dikembangkan lebih lanjut kedepannya

BAB II

TINJAUAN PUSTAKA

2.1 Landasan Teori

2.1.1 Sistem Rekomendasi

Sistem rekomendasi merupakan salah satu bentuk sistem pendukung keputusan (decision support system) yang dirancang untuk membantu pengguna dalam memilih alternatif terbaik dari sejumlah pilihan yang tersedia. Sistem ini bekerja dengan menganalisis data dan karakteristik tertentu untuk menghasilkan rekomendasi yang relevan, kontekstual, dan sesuai dengan kebutuhan pengguna. Dalam lingkungan dengan volume data yang besar, sistem rekomendasi berperan penting dalam menyederhanakan proses pengambilan keputusan serta meningkatkan efisiensi dan akurasi hasil yang diperoleh.

Ricci, Rokach, dan Shapira (2015) mendefinisikan sistem rekomendasi sebagai sistem perangkat lunak yang bertujuan untuk memberikan saran yang bermakna kepada pengguna terkait item atau entitas tertentu dalam suatu domain. Rekomendasi tersebut dapat berupa peringkat, prediksi, maupun daftar item yang diurutkan berdasarkan tingkat kesesuaian. Definisi ini menekankan bahwa sistem rekomendasi tidak hanya berfungsi sebagai penyaring informasi, tetapi juga sebagai alat bantu pengambilan keputusan berbasis data.

2.1.2 Artificial Intelligence

Artificial Intelligence (AI) merupakan bidang ilmu komputer yang berfokus pada pengembangan sistem yang mampu meniru kecerdasan manusia, seperti kemampuan berpikir, belajar, dan mengambil keputusan.

Russell dan Norvig (2021) mendefinisikan AI sebagai studi dan desain agen cerdas yang mampu merasakan lingkungan dan mengambil tindakan untuk mencapai tujuan tertentu. AI menjadi fondasi bagi berbagai aplikasi modern, termasuk sistem

rekomendasi. Dalam penelitian ini, sistem rekomendasi faculty supervisor merupakan salah satu penerapan AI dalam bentuk sistem pendukung keputusan berbasis analisis data tekstual.

2.1.3 Machine Learning

Machine Learning merupakan cabang dari AI yang memungkinkan sistem belajar dari data tanpa diprogram secara eksplisit. Sistem machine learning membangun model berdasarkan pola yang ditemukan dalam data.

Menurut Mitchell (1997), suatu program dikatakan belajar dari pengalaman jika performanya dalam menjalankan suatu tugas meningkat seiring bertambahnya pengalaman. Machine learning banyak digunakan dalam sistem rekomendasi untuk mengenali pola dan hubungan antar data. Dalam penelitian ini, machine learning digunakan melalui model embedding yang mempelajari representasi semantik teks akademik

2.1.4 Deep Learning

Deep Learning merupakan bagian dari machine learning yang menggunakan jaringan saraf tiruan dengan banyak lapisan (deep neural networks) untuk mempelajari representasi data yang kompleks.

LeCun, Bengio, dan Hinton (2015) menjelaskan bahwa deep learning sangat efektif dalam memproses data tidak terstruktur, seperti teks dan gambar. Pendekatan ini menjadi dasar bagi model-model NLP modern. Model embedding berbasis transformer yang digunakan dalam penelitian ini termasuk dalam kategori deep learning.

2.1.5 Natural Language Processing

Natural Language Processing (NLP) merupakan cabang AI yang berfokus pada pemrosesan dan pemahaman bahasa alami manusia oleh komputer. NLP memungkinkan sistem mengekstraksi makna dari data teks.

Jurafsky dan Martin (2023) menyatakan bahwa NLP mencakup berbagai teknik mulai dari pemrosesan dasar hingga analisis semantik tingkat lanjut. NLP menjadi komponen penting dalam sistem rekomendasi berbasis teks. Dalam penelitian ini, NLP digunakan untuk memproses deskripsi minat mahasiswa dan bidang keahlian faculty supervisor.

2.1.6 Text Mining

Text mining merupakan proses ekstraksi informasi dan pola dari data teks. Teknik ini digunakan untuk menemukan pengetahuan baru dari dokumen teks. Dalam penelitian ini, text mining digunakan untuk menganalisis dokumen akademik sebagai dasar rekomendasi faculty supervisor.

2.1.7 Text Preprocessing

Text preprocessing merupakan tahapan pembersihan dan normalisasi teks sebelum dilakukan proses embedding. Tahapan ini bertujuan untuk mengurangi noise dalam data teks dan memastikan konsistensi format input yang akan diproses oleh model embedding.

Dalam penelitian ini, proses text preprocessing menggunakan pendekatan normalisasi minimalis yang terdiri dari tiga langkah, yaitu Case Folding, Pembersihan Karakter Non-Alfanumerik, Collapse Whitespace.

Pendekatan normalisasi ini diimplementasikan melalui fungsi `normalize_text()` yang menggunakan regular expression untuk membersihkan teks secara konsisten. Proses ini diterapkan pada seluruh dokumen teks mahasiswa dan profil dosen sebelum dilakukan embedding.

Pendekatan minimalis ini dipilih berdasarkan pertimbangan bahwa model transformer modern seperti BERT dan turunannya telah dilatih pada korpus teks yang sangat besar dan mampu menangani variasi morfologi, sinonim, dan konteks bahasa secara internal melalui mekanisme tokenisasi subword (WordPiece/BPE).

Oleh karena itu, tahapan preprocessing tambahan seperti stemming dan stop word removal tidak diterapkan untuk menghindari hilangnya informasi kontekstual.

al yang justru dibutuhkan oleh model transformer untuk menghasilkan embedding yang akurat.

2.1.8 Representasi Teks

Representasi teks merupakan proses mengubah data tekstual yang bersifat tidak terstruktur menjadi bentuk numerik agar dapat diproses oleh sistem komputasi. Dalam sistem rekomendasi berbasis teks, representasi teks menjadi faktor krusial karena menentukan sejauh mana sistem mampu memahami dan membandingkan makna antar dokumen secara akurat.

Menurut Manning, Raghavan, dan Schütze (2008), representasi teks merupakan fondasi utama dalam sistem information retrieval dan text mining, karena kualitas representasi secara langsung memengaruhi performa proses pencarian, pengelompokan, dan pengukuran kemiripan dokumen. Representasi teks yang baik harus mampu menangkap informasi penting sekaligus mengurangi noise yang tidak relevan.

Dalam penelitian ini, representasi teks digunakan untuk merepresentasikan profil mahasiswa dan bidang keahlian faculty supervisor dalam bentuk vektor numerik. Representasi ini menjadi dasar dalam perhitungan semantic similarity untuk menghasilkan rekomendasi faculty supervisor Program Enrichment.

2.1.9 TF-IDF

TF-IDF merupakan metode representasi teks klasik yang merepresentasikan dokumen sebagai vektor berdasarkan frekuensi kemunculan kata dalam dokumen dan tingkat kelangkaan kata tersebut dalam keseluruhan koleksi dokumen. Pendekatan ini banyak digunakan dalam sistem pencarian berbasis kata kunci.

Salton dan Buckley (1988) menjelaskan bahwa TF-IDF memberikan bobot yang lebih tinggi pada kata yang sering muncul dalam suatu dokumen namun jarang muncul di dokumen lain, sehingga kata tersebut dianggap lebih representatif terhadap isi dokumen. Dengan demikian, TF-IDF mampu menyoroti kata-kata penting dalam dokumen.

Namun, TF-IDF memiliki keterbatasan dalam memahami makna semantik teks. Metode ini tidak mampu menangkap hubungan sinonim, konteks kalimat, maupun makna laten dari suatu teks. Dua dokumen dengan makna serupa tetapi menggunakan kata yang berbeda dapat memiliki tingkat kemiripan yang rendah.

Dalam penelitian ini, TF-IDF digunakan sebagai baseline konseptual untuk menunjukkan keterbatasan pendekatan berbasis frekuensi kata, sekaligus memperkuat alasan pemilihan metode embedding berbasis transformer yang mampu menangkap makna semantik secara lebih mendalam.

Rumus Term Frequency (TF) adalah sebagai berikut:

$$TF(t, d)$$

$TF(t, d)$ = jumlah kemunculan kata t dalam dokumen d

Rumus Inverse Document Frequency (IDF) adalah sebagai berikut:

$$IDF(t) = \log (N / df(t))$$

Dengan catatan sebagai berikut :

N adalah jumlah seluruh dokumen

$df(t)$ adalah jumlah dokumen yang mengandung kata t

Sehingga rumus TF-IDF dapat dituliskan sebagai berikut:

$$TF - IDF(t, d) = TF(t, d) \times IDF(t)$$

2.1.10 Word Embedding

Word embedding merupakan pendekatan representasi teks yang memetakan kata ke dalam vektor numerik berdasarkan konteks kemunculannya dalam korpus teks. Pendekatan ini memungkinkan sistem untuk menangkap hubungan semantik antar kata dalam ruang vektor.

Mikolov et al. (2013) memperkenalkan Word2Vec yang mempelajari representasi kata berdasarkan konteks lokal, sedangkan Pennington et al. (2014) mengembangkan GloVe yang memanfaatkan statistik global ko-okurensi kata. FastText

(Bojanowski et al., 2017) kemudian memperluas pendekatan ini dengan mempertimbangkan subword, sehingga lebih robust terhadap variasi morfologi kata.

Meskipun word embedding mampu menangkap hubungan semantik antar kata, pendekatan ini bersifat statis, di mana satu kata memiliki satu representasi vektor tetap tanpa mempertimbangkan konteks kalimat. Keterbatasan ini menyebabkan word embedding kurang optimal untuk merepresentasikan makna pada level kalimat atau dokumen.

Dalam penelitian ini, word embedding diposisikan sebagai tahap evolusi setelah TF-IDF dan sebelum embedding kontekstual. Keterbatasannya menjadi dasar pemilihan transformer-based embedding yang digunakan dalam sistem rekomendasi.

2.1.11 Transformer-Based Embedding

Transformer-based embedding merupakan pendekatan representasi teks modern yang memanfaatkan arsitektur transformer untuk menghasilkan embedding yang bersifat kontekstual. Arsitektur transformer diperkenalkan oleh Vaswani et al. (2017) dan menggunakan mekanisme self-attention untuk memodelkan hubungan antar kata dalam suatu teks secara menyeluruh.

Devlin et al. (2019) menjelaskan bahwa model berbasis transformer mampu menghasilkan representasi teks kontekstual, di mana makna suatu kata dipengaruhi oleh keseluruhan konteks kalimat. Pendekatan ini memungkinkan sistem memahami hubungan semantik yang kompleks, termasuk sinonim dan konteks implisit.

Dalam penelitian ini, transformer-based embedding digunakan karena kemampuannya dalam merepresentasikan dokumen teks akademik secara lebih akurat. Pendekatan ini sangat sesuai untuk membandingkan deskripsi minat mahasiswa dan bidang keahlian faculty supervisor yang memiliki variasi istilah dan gaya bahasa.

2.1.12 Bert Embedding

BERT (Bidirectional Encoder Representations from Transformers) merupakan model berbasis transformer yang menghasilkan representasi teks dua arah (bidirectional), sehingga setiap token dipahami berdasarkan konteks sebelum dan sesudah-

nya.

Menurut Devlin et al. (2019), BERT menghasilkan embedding kontekstual yang lebih kaya dibandingkan model sebelumnya karena mempertimbangkan konteks secara menyeluruh. BERT menjadi tonggak penting dalam perkembangan NLP modern.

Dalam penelitian ini, konsep BERT embedding digunakan sebagai landasan teoretis bagi penggunaan model embedding kontekstual modern. Meskipun penelitian ini tidak terbatas pada BERT saja, prinsip representasi kontekstual yang diperkenalkan BERT menjadi dasar bagi model embedding lain yang digunakan.

2.1.13 Semantic Similarity

Semantic similarity merupakan ukuran tingkat kesamaan makna antara dua teks atau konsep berdasarkan konteks dan arti, bukan sekadar kecocokan kata secara literal. Pendekatan ini memungkinkan sistem memahami kesamaan konsep meskipun menggunakan istilah yang berbeda.

Menurut Mihalcea et al. (2006), semantic similarity bertujuan untuk mengukur sejauh mana dua unit teks memiliki makna yang serupa. Pendekatan ini banyak digunakan dalam sistem rekomendasi dan pencarian semantik modern. Dalam penelitian ini, semantic similarity digunakan untuk mengukur tingkat kesesuaian antara profil mahasiswa dan bidang keahlian faculty supervisor, sehingga rekomendasi yang dihasilkan lebih relevan secara konseptual.

2.1.14 Cosine Similarity

Cosine similarity merupakan metode yang umum digunakan untuk mengukur kemiripan antara dua vektor dengan menghitung cosinus sudut di antara keduanya. Nilai cosine similarity berada pada rentang -1 hingga 1.

Menurut Han, Kamber, dan Pei (2012), cosine similarity efektif digunakan dalam pengukuran kemiripan dokumen karena tidak dipengaruhi oleh panjang vektor. Metode ini banyak digunakan dalam sistem berbasis embedding.

Dalam penelitian ini, cosine similarity digunakan untuk menghitung tingkat ke-

miripan antara embedding teks mahasiswa dan faculty supervisor sebagai dasar pemeringkatan rekomendasi.

Rumus Cosine Similarity adalah sebagai berikut:

$$\text{Cosine Similarity} = \frac{(A \cdot B)}{(\|A\| \times \|B\|)}$$

Dengan catatan sebagai berikut :

A dan B adalah vektor embedding

$A \cdot B$ adalah hasil perkalian dot product antara vektor A dan B

$\|A\|$ dan $\|B\|$ adalah panjang (norma) dari masing-masing vektor

2.1.15 Text Embedding & Model Embedding

Text embedding merupakan teknik untuk merepresentasikan teks dalam bentuk vektor numerik berdimensi tinggi yang merepresentasikan makna semantik. Embedding memungkinkan perbandingan teks dilakukan secara matematis. Menurut Reimers dan Gurevych (2019), embedding berbasis transformer menunjukkan performa yang unggul dalam tugas semantic similarity dan retrieval dibandingkan metode representasi tradisional. Dalam penelitian ini, beberapa model embedding berbasis transformer digunakan untuk membandingkan performa sistem rekomendasi, termasuk model berskala besar dan model ringan.

2.1.16 BGE-M3 (BAAI/bge-m3)

BGE-M3 merupakan model embedding multilingual yang dikembangkan oleh Beijing Academy of Artificial Intelligence (BAAI). Model ini dirancang untuk mendukung tiga fungsi sekaligus: dense retrieval, sparse retrieval, dan multi-vector retrieval, sehingga dinamakan M3 (Multi-Functionality, Multi-Linguality, Multi-Granularity).

Menurut Chen et al. (2024), BGE-M3 mendukung lebih dari 100 bahasa dan mampu memproses teks hingga 8.192 token. Model ini menunjukkan performa kompetitif pada berbagai benchmark retrieval lintas bahasa. Dalam penelitian ini, BGE-M3 digunakan sebagai salah satu kandidat model embedding untuk mengevaluasi kualitas rekomendasi faculty supervisor.

2.1.17 Qwen3-Embedding-0.6B

Qwen3-Embedding merupakan model embedding dari keluarga Qwen yang dikembangkan oleh Alibaba Group Y. Zhang et al. (2025). Varian 0.6B memiliki 600 juta parameter dan dirancang untuk keseimbangan antara performa dan efisiensi komputasi.

Model ini mendukung pemrosesan teks multilingual dan dioptimalkan untuk tugas semantic search dan text matching. Dalam penelitian ini, Qwen3-Embedding-0.6B digunakan untuk mengevaluasi trade-off antara ukuran model yang lebih kecil dan kualitas embedding yang dihasilkan.

2.1.18 Multilingual E5-Large-Instruct (intfloat/multilingual-e5-large-instruct)

Multilingual E5 merupakan model embedding yang dikembangkan oleh Microsoft Research. Varian large-instruct memiliki sekitar 560 juta parameter dan mendukung pemrosesan teks dalam lebih dari 90 bahasa.

Menurut Wang et al. (2024), model E5 yang dilengkapi instruction tuning menunjukkan peningkatan performa pada tugas retrieval dan semantic similarity dibandingkan model tanpa instruction. Dalam penelitian ini, Multilingual E5-Large-Instruct digunakan sebagai model default karena performa yang konsisten pada teks campuran Bahasa Indonesia dan Bahasa Inggris yang terdapat dalam data akademik.

2.1.19 Evaluasi Sistem Rekomendasi

Evaluasi sistem rekomendasi merupakan proses untuk menilai kualitas, relevansi, dan efektivitas rekomendasi yang dihasilkan oleh sistem. Evaluasi bertujuan untuk memastikan sistem memenuhi tujuan fungsional dan kebutuhan pengguna.

Menurut Shani dan Gunawardana (2011), evaluasi sistem rekomendasi dapat dilakukan menggunakan metrik berbasis relevansi dan peringkat. Evaluasi yang baik harus mencerminkan kondisi penggunaan sistem secara nyata.

Dalam penelitian ini, evaluasi sistem rekomendasi dilakukan menggunakan evaluasi otomatis berbasis metrik kuantitatif, yaitu dengan membandingkan rekomendasi terhadap *ground truth* (mapping dosen pembimbing aktual dari data EPC). Metrik yang digunakan meliputi Mean Reciprocal Rank (MRR), Hit@1 dan Hit@5, nDCG@5 dan nDCG@10, Precision@5, Average Rank, dan Assignment Match Rate. Evaluasi ini dilakukan pada tiga tingkat skor, yaitu Content-Based, Hybrid Score, dan Assignment Match.

2.1.20 Hit@K

Hit@K merupakan metrik evaluasi yang mengukur apakah item relevan (ground truth) berhasil muncul dalam K rekomendasi teratas. Nilai Hit@K adalah 1 jika item relevan berada dalam top-K, dan 0 jika tidak.

$$Hit@K = 1 \text{ jika } rank \leq K, 0 \text{ jika } rank > K$$

Rata-rata Hit@K dihitung sebagai:

$$Avg \text{ Hit@K} = (1/N) \times \sum Hit@K_i$$

2.1.21 Normalized Discounted Cumulative Gain (nDCG@K)

nDCG@K merupakan metrik evaluasi yang mengukur kualitas peringkat rekomendasi dengan memberikan bobot lebih besar pada item relevan yang muncul di posisi awal. Metrik ini memperhitungkan posisi item relevan dalam daftar peringkat menggunakan faktor diskon logaritmik.

$$Rumus \text{ DCG@K} = \sum_{i=1}^K \left(\frac{rel_i}{\log_2(i+1)} \right)$$

$$Rumus \text{ nDCG@K} = \frac{DCG@K}{IDCG@K}$$

2.1.22 Recall@K

Recall@K merupakan metrik evaluasi yang mengukur proporsi item relevan yang berhasil muncul dalam K rekomendasi teratas. Recall@K mengukur proporsi item relevan yang berhasil direkomendasikan oleh sistem dalam K rekomendasi teratas. Metrik ini menilai kemampuan sistem dalam menemukan item yang relevan, bukan urutannya

Herlocker et al. (2004) menyatakan bahwa Recall@K sangat sesuai untuk sistem rekomendasi berbasis peringkat karena merepresentasikan kemampuan sistem dalam menemukan item relevan pada daftar rekomendasi teratas.

Dalam penelitian ini, Recall@K digunakan untuk mengukur sejauh mana faculty supervisor yang relevan berhasil direkomendasikan oleh sistem pada posisi teratas.

Rumus Recall@K dapat dituliskan sebagai berikut:

$$Recall@K = \frac{jumlah\ item\ relevan\ dalam\ Top - K}{total\ item\ relevan}$$

Nilai Recall@K berada pada rentang 0 hingga 1. Semakin tinggi nilai Recall@K, semakin baik kemampuan sistem dalam menemukan item relevan.

2.1.23 Precision@K

Precision@K mengukur proporsi item relevan dalam K rekomendasi teratas.

$$Precision@K = \frac{jumlah\ item\ relevan\ dalam\ top - K}{K}$$

2.1.24 Mean Reciprocal Rank (MRR)

Mean Reciprocal Rank (MRR) merupakan metrik evaluasi yang mengukur posisi item relevan pertama dalam daftar rekomendasi. Mean Reciprocal Rank (MRR) mengukur seberapa cepat item relevan pertama muncul dalam daftar rekomendasi. MRR memberikan bobot lebih besar pada rekomendasi relevan yang muncul di peringkat awal.

Menurut Voorhees (1999), MRR memberikan bobot lebih besar pada item relevan yang muncul di peringkat awal, sehingga cocok untuk sistem rekomendasi yang mengutamakan urutan hasil.

Dalam penelitian ini, MRR digunakan untuk menilai seberapa cepat sistem menampilkan faculty supervisor yang sesuai dalam daftar rekomendasi.

Rumus Reciprocal Rank (RR) adalah sebagai berikut:

$$RR = \frac{1}{\text{peringkat item relevan pertama}}$$

Rumus Mean Reciprocal Rank (MRR) adalah sebagai berikut:

$$MRR = \left(\frac{1}{N} \right) \times \sum RR_i$$

Dengan catatan sebagai berikut :

N adalah jumlah total data uji

RR_i adalah nilai reciprocal rank untuk data ke-i

2.1.25 Cosine Similarity Score

Cosine similarity score merupakan ukuran kemiripan antara dua vektor berdasarkan sudut di antaranya. Cosine similarity mengukur kemiripan antara dua vektor embedding berdasarkan sudut di antara keduanya. Nilai cosine similarity berada pada rentang -1 hingga 1.

Menurut Manning et al. (2008), cosine similarity banyak digunakan dalam model ruang vektor karena tidak dipengaruhi oleh panjang vektor. Dalam penelitian ini, cosine similarity score digunakan sebagai dasar perhitungan kesesuaian semantik antara embedding mahasiswa dan faculty supervisor.

2.1.26 Assignment match rate

Assignment match rate merupakan metrik spesifik untuk evaluasi sistem assignment yang mengukur proporsi penugasan akhir yang cocok dengan ground truth (mapping dosen aktual).

Match Rate = jumlah assignment cocok / total assignment yang memiliki ground truth

2.1.27 Teknologi Pendukung Sistem

Teknologi pendukung sistem merupakan komponen perangkat lunak dan infrastruktur yang digunakan untuk mengembangkan dan menjalankan sistem rekomendasi. Pemilihan teknologi harus mempertimbangkan skalabilitas, efisiensi, dan kemudahan integrasi.

2.1.28 Python

Python merupakan bahasa pemrograman tingkat tinggi yang banyak digunakan dalam pengembangan sistem berbasis data, kecerdasan buatan, dan pemrosesan bahasa alami. Python dikenal memiliki sintaks yang sederhana, mudah dibaca, serta didukung oleh ekosistem pustaka yang sangat luas.

Menurut Van Rossum dan Drake (2009), Python dirancang untuk meningkatkan produktivitas pengembang melalui struktur sintaks yang ringkas dan dukungan paradigma pemrograman yang fleksibel. Dalam domain kecerdasan buatan dan machine learning, Python menjadi bahasa *de facto* karena dukungan pustaka seperti NumPy, PyTorch, dan Scikit-learn.

Dalam penelitian ini, Python digunakan sebagai bahasa utama pada sisi backend untuk mengembangkan sistem rekomendasi faculty supervisor. Python digunakan untuk mengelola alur pemrosesan data, integrasi model text embedding, perhitungan semantic similarity, serta evaluasi sistem rekomendasi.

2.1.29 JavaScript

JavaScript merupakan bahasa pemrograman yang digunakan secara luas dalam pengembangan aplikasi berbasis web, khususnya pada sisi klien (client-side). JavaScript memungkinkan pembuatan antarmuka pengguna yang interaktif dan dinamis.

Menurut Flanagan (2020), JavaScript berperan penting dalam pengembangan aplikasi web modern karena mampu berjalan langsung di browser dan mendukung komunikasi asinkron dengan backend melalui HTTP.

Dalam penelitian ini, JavaScript digunakan pada sisi frontend untuk membangun antarmuka sistem rekomendasi faculty supervisor. JavaScript memungkinkan

pengguna memasukkan data, memicu proses rekomendasi, dan menampilkan hasil rekomendasi secara interaktif.

2.1.30 Flask + Jinja2

Flask merupakan micro web framework berbasis Python yang digunakan untuk membangun aplikasi web. Flask mengadopsi pendekatan minimalis dengan menyediakan komponen inti seperti routing, templating, dan session management, namun tetap fleksibel untuk diperluas melalui ekstensi.

Menurut Grinberg (2018), Flask dirancang dengan filosofi "micro" yang berarti framework ini menyediakan fondasi dasar tanpa memaksakan struktur proyek tertentu, sehingga pengembang memiliki kebebasan dalam menentukan arsitektur aplikasi. Flask menggunakan Jinja2 sebagai template engine untuk menghasilkan halaman HTML secara dinamis di sisi server (server-side rendering).

Dalam penelitian ini, Flask digunakan sebagai framework utama untuk membangun antarmuka web sistem rekomendasi faculty supervisor. Flask menangani seluruh alur request-response, termasuk autentikasi pengguna, import data, pemrosesan rekomendasi, dan penyajian hasil dalam bentuk halaman web interaktif. Pendekatan server-side rendering dipilih karena kesederhanaan arsitektur dan kesesuaiannya dengan skala sistem yang bersifat single-user.

2.1.31 Pytorch

PyTorch merupakan framework deep learning berbasis Python yang mendukung komputasi tensor dan pengembangan model neural network. PyTorch banyak digunakan dalam penelitian dan pengembangan model berbasis transformer.

Menurut Paszke et al. (2019), PyTorch menyediakan fleksibilitas tinggi dalam pengembangan model deep learning serta mendukung eksekusi dinamis (dynamic computation graph), yang memudahkan eksperimen model.

Dalam penelitian ini, PyTorch digunakan sebagai framework pendukung untuk menjalankan dan mengelola model text embedding berbasis transformer yang digunakan dalam sistem rekomendasi.

2.1.32 SQLite

SQLite merupakan sistem manajemen basis data relasional yang bersifat embedded dan file-based. Berbeda dengan sistem database client-server seperti PostgreSQL, SQLite tidak memerlukan proses server terpisah dan menyimpan seluruh database dalam satu file tunggal.

Menurut Owens (2006), SQLite cocok digunakan pada aplikasi yang memerlukan penyimpanan data terstruktur tanpa overhead konfigurasi server database. SQLite mendukung sebagian besar fitur SQL standar dan banyak digunakan dalam prototipe sistem dan aplikasi skala kecil hingga menengah.

Dalam penelitian ini, SQLite digunakan sebagai database utama untuk menyimpan data mahasiswa, profil dosen, konfigurasi aturan, serta hasil rekomendasi. Pemilihan SQLite atas PostgreSQL didasarkan pada pertimbangan bahwa sistem ini berjalan sebagai proses tunggal (single-process) dan tidak memerlukan fitur vector store, karena perhitungan similarity dilakukan secara on-the-fly menggunakan operasi matriks NumPy.

2.1.33 SQLAlchemy

SQLAlchemy merupakan pustaka Object-Relational Mapping (ORM) untuk Python yang menyediakan abstraksi antara kode aplikasi dan database relasional. ORM memungkinkan pengembang untuk berinteraksi dengan database menggunakan objek Python tanpa menulis query SQL secara langsung.

Menurut Copeland (2008), SQLAlchemy menyediakan dua lapisan abstraksi: Core (SQL Expression Language) dan ORM (Object-Relational Mapping), yang memungkinkan fleksibilitas dalam tingkat kontrol terhadap database. SQLAlchemy mendukung berbagai backend database termasuk SQLite, PostgreSQL, dan MySQL.

Dalam penelitian ini, SQLAlchemy digunakan untuk mendefinisikan skema database melalui deklarasi model Python, mengelola sesi transaksi, dan melakukan query data secara terstruktur. Pendekatan ORM memisahkan logika bisnis dari detail implementasi database, sehingga kode lebih mudah dipelihara dan diuji.

2.1.34 Sentence-Transformers

Sentence-Transformers merupakan pustaka Python yang menyediakan antarmuka untuk menghasilkan embedding pada level kalimat dan dokumen menggunakan model transformer. Pustaka ini memungkinkan proses encoding teks dilakukan secara lokal tanpa memerlukan layanan API eksternal.

Menurut Reimers dan Gurevych (2019), Sentence-BERT (SBERT) menggunakan arsitektur siamese network untuk menghasilkan embedding kalimat yang dapat dibandingkan secara langsung menggunakan cosine similarity. Pendekatan ini secara signifikan lebih efisien dibandingkan melakukan cross-encoding untuk setiap pasangan kalimat.

Dalam penelitian ini, sentence-transformers digunakan sebagai mekanisme utama untuk menghasilkan embedding teks mahasiswa dan faculty supervisor. Proses encoding dilakukan secara batch dengan normalisasi embedding, sehingga cosine similarity dapat dihitung melalui operasi dot product sederhana. Pustaka ini mendukung eksekusi pada GPU (CUDA) maupun CPU, dengan deteksi perangkat secara otomatis.

2.1.35 Post Forwarding

Port forwarding merupakan teknik jaringan yang memungkinkan akses ke layanan internal melalui jaringan eksternal dengan meneruskan permintaan dari port tertentu ke layanan internal.

Menurut Kurose dan Ross (2017), port forwarding sering digunakan untuk mengakses layanan server yang berada di balik firewall atau jaringan privat.

Dalam penelitian ini, port forwarding digunakan untuk memungkinkan akses ke layanan backend dan layanan embedding yang berjalan pada lingkungan on-premises selama tahap pengujian dan deployment sistem

2.1.36 On-Premises Deployment

On-premises deployment merupakan model penyebaran sistem di mana aplikasi dijalankan pada infrastruktur lokal, bukan pada layanan cloud publik. Menurut Mell

dan Grance (2011), pendekatan on-premises memberikan kontrol penuh terhadap data dan infrastruktur.

Dalam penelitian ini, sistem rekomendasi faculty supervisor di-deploy secara lokal menggunakan Docker container. Arsitektur deployment terdiri dari satu container aplikasi Flask yang menjalankan seluruh komponen sistem, termasuk web server, pipeline rekomendasi, dan database SQLite. Model embedding diunduh dan dijalankan secara lokal melalui pustaka sentence-transformers, tanpa memerlukan layanan API eksternal.

Pendekatan on-premises dipilih untuk menjaga keamanan data akademik mahasiswa dan memenuhi kebijakan institusi pendidikan terkait pengelolaan data sensitif.

2.1.37 Unified Modeling Language

Menurut Dennis, Wixom, and Roth (2020) Unified Modeling Language (UML) adalah alat diagramatis yang digunakan untuk memodelkan sistem berbasis objek dalam software engineering. UML berfungsi sebagai bahasa standar yang menyediakan terminologi dan teknik diagram yang seragam untuk mendukung semua fase pengembangan sistem, mulai dari analisis kebutuhan hingga implementasi.

2.1.38 Usecase Diagram

Use-case merupakan salah satu elemen penting dalam Unified Modeling Language (UML) yang digunakan untuk memahami fungsi fungsi utama dari sistem secara umum. Use-case diagrams berperan penting dalam mengkomunikasikan secara sederhana kepada pengguna mengenai apa yang akan dilakukan oleh sistem, sehingga diagram ini umumnya dibuat pada tahap pengumpulan dan penentuan kebutuhan sistem. Dengan menyediakan representasi visual yang sederhana, Use-case diagram dapat mendorong pengguna untuk memberikan masukan tambahan terkait kebutuhan sistem pada tingkat yang lebih tinggi. Diagram ini menggambarkan fungsi utama dari sistem serta berbagai jenis pengguna yang akan berinteraksi dengan sistem tersebut Dennis et al. (2020).

2.1.39 Activity Diagram

Activity diagram digunakan untuk merepresentasikan perilaku dalam proses bisnis yang tidak bergantung pada objek (independen). Activity diagram dapat digunakan untuk memodelkan segala sesuatu mulai dari alur kerja bisnis tingkat tinggi yang melibatkan banyak use case yang berbeda, hingga detail use case individual, hingga detail spesifik dari metode individual. Singkatnya, diagram aktivitas dapat digunakan untuk memodelkan semua jenis proses Dennis et al. (2020).

2.1.40 Class Diagram

Class diagram adalah salah satu jenis diagram pada UML yang merupakan model statis yang menunjukkan kelas-kelas dan hubungan antar kelas yang tetap konstan dalam sistem dari waktu ke waktu. Diagram ini menggambarkan kelas-kelas yang mencakup perilaku (behavior) dan keadaan (state), serta memperlihatkan hubungan di antara kelas-kelas tersebut. Diagram kelas digunakan untuk memodelkan struktur sistem secara konseptual dengan menekankan pada elemen-elemen yang saling terkait dalam suatu sistem perangkat lunak. Unsur-unsur dalam diagram kelas meliputi atribut, metode, dan relasi seperti asosiasi, pewarisan, serta agregasi Dennis et al. (2020).

2.1.41 Entity Relationship Diagram

Entity Relationship Diagram (ERD) adalah representasi visual yang digunakan dalam analisis sistem untuk memodelkan informasi yang diciptakan, disimpan, dan digunakan oleh suatu sistem bisnis. Diagram ini membantu analis memahami berbagai komponen informasi serta hubungan antar komponen dalam sistem tersebut. Dalam ERD, data yang serupa dikelompokkan menjadi entities, yang direpresentasikan dengan kotak-kotak. Hubungan antar entities ditunjukkan dengan garis, dan simbol-simbol digunakan untuk menggambarkan aturan bisnis tingkat tinggi. Setiap entity memiliki atribut yang menjelaskan informasi spesifik terkait dengannya, dan hubungan antar entities digambarkan untuk menunjukkan bagaimana mereka saling berinteraksi atau saling tergantung satu sama lain. ERD sangat penting da-

lam mengorganisir data sistem tanpa menunjukkan urutan atau alur spesifik antara entities.

2.2 Penelitian Terkait

Peneliti	Judul	Tujuan	Dataset	Model	Hasil
Zhang et al. (2016)	A Personality Matching-Aided Approach for Supervisor Recommendation	Mengusulkan pendekatan rekomendasi supervisor yang mempertimbangkan kesesuaian kepribadian antara mahasiswa dan supervisor	Data mahasiswa dan supervisor dari institusi pendidikan	Personality Matching, Recommendation Algorithm	Pendekatan berbasis kepribadian dapat memperkuat relevansi rekomendasi supervisor dibandingkan pendekatan berbasis topik penelitian semata
Cohan et al. (2020)	SPECTER: Document-level Representation Learning using Citation-informed Transformers	Mengembangkan representasi embedding dokumen ilmiah berbasis transformer yang memanfaatkan grafik kutipan untuk meningkatkan kemiripan semantik antar makalah ilmiah	Data makalah ilmiah dari Semantic Scholar Open Research Corpus (S2ORC)	BERT + Citation Graph (SPECTER)	SPECTER menghasilkan embedding dokumen yang lebih unggul dibandingkan BERT standar pada tugas klasifikasi makalah, pengelompokan dokumen, dan pencocokan reviewer-paper

Peneliti	Judul	Tujuan	Dataset	Model	Hasil
Nagarajan et al. (2025)	A BERT Based Hybrid Recommendation System For Academic Collaboration	Membangun sistem rekomendasi kolaborasi akademik berbasis profil institusi menggunakan pendekatan hibrida TF-IDF dan BERT	Data profil akademik mahasiswa dan dosen di lingkungan universitas	TF-IDF, BERT, Hybrid + Affinity Propagation Clustering	Pendekatan hibrida BERT mengungguli TF-IDF dan BERT tunggal dalam pencocokan profil akademik; clustering Affinity Propagation meningkatkan akurasi rekomendasi
Wang et al. (2025)	Empowering College Students to Select Ideal Advisors: A Text-Based Recommendation Model	Membangun model rekomendasi pembimbing akademik berbasis teks untuk membantu mahasiswa memilih pembimbing yang sesuai dengan minat penelitian	Data rekam jejak pembimbing dan kuesioner dari 170 mahasiswa perguruan tinggi	Chinese BERT + SimCSE (unsupervised contrastive learning)	Model AVR D melampaui TF-IDF, LSA, Word2Vec, serta model LLM Qwen dan DeepSeek dalam relevansi rekomendasi pembimbing akademik

Peneliti	Judul	Tujuan	Dataset	Model	Hasil
Sabilillah et al. (2024)	Implementasi BERT dan Cosine Similarity untuk Rekomendasi Dosen Pembimbing berdasarkan Judul Tugas Akhir	Mengimplementasi BERT dan cosine similarity untuk merekomendasikan dosen pembimbing berdasarkan judul tugas akhir	Data judul tugas akhir mahasiswa dan profil dosen	BERT, Cosine Similarity	BERT + cosine similarity menunjukkan performa yang lebih baik dalam mengukur kemiripan semantik antara judul tugas akhir dan keahlian dosen
Dasri et al. (2025)	Two-Way Thesis Supervisor Recommendation System Using MapReduce K-Skyband View Queries	Mengembangkan sistem rekomendasi pembimbing tugas akhir dua arah yang mempertimbangkan preferensi mahasiswa dan dosen secara bersamaan	Data historis mahasiswa dan supervisor di institusi pendidikan tinggi	MapReduce K-Skyband View Queries	Pendekatan MapReduce $8\times$ lebih cepat dari algoritma Block Nested Loop standar pada dataset besar dengan kualitas rekomendasi yang terjaga

Tabel 2.1. Tabel Penelitian Terkait

Berdasarkan kajian terhadap penelitian-penelitian terkait, dapat disimpulkan bahwa sistem rekomendasi faculty supervisor umumnya dikembangkan menggunakan pendekatan Natural Language Processing untuk mengukur kesesuaian antara profil mahasiswa dan bidang keahlian dosen. Perkembangan metode menunjukkan pergeseran dari representasi teks tradisional seperti TF-IDF Dasri et al. (2025) menuju penggunaan transformer-based embedding seperti BERT Sabilillah et al. (2024); X. Wang et al. (2025) dan SPECTER Cohan et al. (2020), yang terbukti mampu meningkatkan kualitas rekomendasi berdasarkan berbagai metrik evaluasi,


seperti akurasi, Recall@K, dan Mean Reciprocal Rank (MRR).

Meskipun demikian, terdapat kesenjangan yang belum ditangani oleh penelitian terdahulu. Penelitian yang menggunakan sentence embedding untuk rekomendasi akademik, seperti rekomendasi jurnal ilmiah Gündoğan, Kaya, and Daud (2023) dan pencocokan profil karier Rosenberger, Wolfrum, Weinzierl, Kraus, and Zschech (2025), umumnya masih mengandalkan model SBERT atau BERT yang di-*fine-tune* pada domain tertentu dan bersifat monolingual. Belum ada penelitian yang menerapkan model embedding multilingual generasi terbaru — yaitu BGE-M3 Chen et al. (2024), *multilingual-e5-large-instruct* L. Wang et al. (2024), dan Qwen3-Embedding Y. Zhang et al. (2025) — secara komparatif untuk sistem rekomendasi faculty supervisor dalam konteks akademik Indonesia yang bersifat dwibahasa. Selain itu, penelitian terdahulu juga belum mengintegrasikan sistem rekomendasi ke dalam *decision support system* berbasis web yang mempertimbangkan batasan kuota dan pemerataan beban pembimbingan secara institusional. Oleh karena itu, penelitian ini mengusulkan sistem rekomendasi faculty supervisor Program Enrichment yang mengombinasikan tiga model *zero-shot multilingual dense retrieval* dengan aturan pendukung institusional, serta melakukan evaluasi komparatif menggunakan Recall@K dan MRR untuk mengidentifikasi model terbaik dalam konteks tersebut.

BAB III

METODE PENELITIAN

3.1 Kerangka Berpikir



Gambar 3.1. Alur Kerangka Berpikir

Proses penentuan faculty supervisor untuk mahasiswa saat ini dilakukan secara manual oleh pihak EPC. Namun, proses penentuan faculty supervisor tersebut memiliki beberapa keterbatasan antara lain waktu yang relatif lama, bergantung pada pengetahuan individu tertentu, serta tidak sepenuhnya mempertimbangkan kesesuaian antara keahlian faculty supervisor dan kepentingan atau posisi mahasiswa.

Selain itu, proses manual ini kurang transparan karena tidak didukung mekanisme pencocokan yang terstruktur dan berbasis data.

Dalam upaya mengatasi keterbatasan tersebut, pendekatan pencocokan berbasis teks sering digunakan sebagai solusi awal. Pendekatan pencocokan berbasis kata kunci merupakan metode umum dalam information retrieval tradisional yang mengukur kesamaan dokumen berdasarkan kemunculan kata atau frekuensi istilah tertentu. Pendekatan ini memiliki keterbatasan dalam menangkap kesamaan makna antara teks yang menggunakan istilah berbeda namun memiliki konteks yang serupa.

Permasalahan tersebut menuntut adanya sebuah sistem yang dapat membantu proses pemetaan antara faculty supervisor dan mahasiswa secara lebih objektif dan efisien. Berdasarkan kebutuhan tersebut, penelitian ini mengusulkan pengembangan sistem rekomendasi untuk mengotomatisasi proses pencocokan mahasiswa dengan faculty supervisor. Pendekatan scoring yang digunakan menggabungkan dua komponen utama, yaitu semantic similarity berbasis text embedding untuk mengukur kesesuaian makna antara profil mahasiswa dan dosen, serta company group bonus untuk mempertimbangkan pengelompokan mahasiswa berdasarkan perusahaan tempat kerja.

Sistem yang dikembangkan memanfaatkan informasi tekstual yang bersumber dari profil faculty supervisor dan data mahasiswa. Informasi tersebut direpresentasikan dalam bentuk dokumen teks yang menggambarkan karakteristik akademik dan konteks profesional masing-masing entitas. Pendekatan semantic similarity dipilih sebagai komponen utama karena mampu memahami makna dan konteks teks secara lebih mendalam dibandingkan metode pencocokan berbasis kata kunci. Company group bonus digunakan untuk mendorong konsistensi penempatan mahasiswa dari perusahaan yang sama pada faculty supervisor yang paling sesuai.

Berdasarkan skor hybrid yang dihasilkan, sistem menggunakan greedy capacity-constrained solver untuk mengalokasikan setiap mahasiswa ke satu faculty supervisor secara optimal dengan mempertimbangkan batasan kapasitas bimbingan minimum dan maksimum per faculty supervisor. Hasil akhir berupa pasangan mahasiswa dan faculty supervisor yang telah memenuhi seluruh constraint kapasitas.

Pengembangan sistem dilakukan melalui beberapa tahapan yang saling berurutan, dimulai dari analisis permasalahan dan kebutuhan sistem, perencanaan proses pengembangan, perancangan model rekomendasi, hingga implementasi sistem dalam bentuk aplikasi berbasis website. Kerangka berpikir penelitian ini digambarkan dalam bentuk diagram alur pada Gambar 3.1, yang menunjukkan hubungan antara permasalahan, metode yang digunakan, dan keluaran sistem berupa rekomendasi faculty supervisor untuk mahasiswa.

3.2 Metodologi Penelitian

3.2.1 Analisis

3.2.2 Analisis Permasalahan

Penentuan faculty supervisor untuk mahasiswa saat ini masih dilakukan secara manual oleh pihak EPC. Proses tersebut bergantung pada pengetahuan dan pengalaman individu yang menjalankan peran EPC, tanpa adanya aturan pencocokan yang terstruktur dan berbasis data. Akibatnya, proses pemetaan antara mahasiswa dan faculty supervisor membutuhkan waktu yang relatif lama serta berpotensi menimbulkan subjektivitas dalam pengambilan keputusan.

Selain itu, proses manual ini juga kurang transparan karena tidak didukung oleh mekanisme yang dapat menjelaskan alasan pemilihan faculty supervisor tertentu untuk seorang mahasiswa. Kondisi tersebut menyulitkan evaluasi terhadap hasil pemetaan yang telah dilakukan serta berpotensi menyebabkan distribusi beban bimbingan faculty supervisor yang tidak merata, terutama terkait keterbatasan slot bimbingan yang dimiliki oleh masing-masing faculty supervisor.

Permasalahan-permasalahan tersebut menunjukkan perlunya suatu sistem yang mampu membantu proses pemetaan faculty supervisor dan mahasiswa secara lebih objektif, efisien, serta transparan dengan memanfaatkan data yang tersedia.

Pada penelitian ini, sistem rekomendasi dikembangkan sebagai decision support system untuk membantu EPC dalam proses pemetaan faculty supervisor dan mahasiswa. Perancangan sistem, termasuk UML dan use case, digunakan sebagai media

untuk memastikan integrasi metode semantic similarity berjalan sesuai dengan skenario penelitian. Fokus utama penelitian ini bukan pada kompleksitas implementasi sistem, melainkan pada evaluasi kualitas rekomendasi yang dihasilkan oleh pendekatan semantic similarity.

3.2.3 Analisis Permasalahan

Dalam konteks penelitian ini, EPC berperan sebagai administrator sistem yang bertanggung jawab terhadap pengelolaan data mahasiswa, data faculty supervisor, serta informasi pendukung lainnya. EPC merupakan satu-satunya aktor yang berinteraksi langsung dengan sistem rekomendasi.

Mahasiswa dan faculty supervisor tidak diposisikan sebagai aktor yang berinteraksi dengan sistem, melainkan sebagai entitas data yang diproses dalam mekanisme rekomendasi. Mahasiswa berperan sebagai objek rekomendasi yang akan dicocokkan dengan profil faculty supervisor berdasarkan kesesuaian informasi akademik dan posisi kerja, sedangkan faculty supervisor berperan sebagai kandidat yang akan direkomendasikan oleh sistem.

Dengan pemisahan peran tersebut, sistem difokuskan sebagai decision support system yang bertujuan untuk membantu EPC dalam pengambilan keputusan pemetaan faculty supervisor dan mahasiswa secara sistematis dan berbasis data, tanpa menggantikan keputusan akhir yang tetap berada pada pihak EPC.

3.2.4 Analisis Kebutuhan Sistem

3.2.5 Kebutuhan Fungsional

Berdasarkan analisis permasalahan dan aktor sistem, kebutuhan fungsional yang harus dipenuhi oleh sistem rekomendasi adalah sebagai berikut:

Tabel 3.1. Tabel 3. Analisis Kebutuhan Fungsional

No	Kebutuhan Fungsional
1	Sistem mampu mengelola data mahasiswa yang mencakup informasi posisi kerja dan perusahaan
2	Sistem mampu mengelola data profil faculty supervisor
3	Sistem mampu memproses data teks yang berasal dari mahasiswa dan faculty supervisor
4	Sistem mampu mengidentifikasi tingkat kesesuaian antara mahasiswa dan faculty supervisor berdasarkan informasi yang tersedia
5	Sistem mampu melakukan pengurutan (ranking) faculty supervisor berdasarkan tingkat kesesuaian
6	Sistem mampu mempertimbangkan ketersediaan slot bimbingan faculty supervisor dalam menghasilkan rekomendasi
7	Sistem mampu menampilkan hasil rekomendasi faculty supervisor untuk setiap mahasiswa

3.2.6 Kebutuhan Non-Fungsional

Tabel 3.2. Tabel 3. Analisis Kebutuhan Non-Fungsional

No	Kebutuhan Non-Fungsional
1	Sistem berbasis website sehingga dapat diakses dengan mudah oleh EPC
2	Sistem memiliki antarmuka yang sederhana dan mudah digunakan
3	Sistem mampu menampilkan hasil rekomendasi secara transparan dan konsisten
4	Sistem mendukung pengelolaan data secara terstruktur

3.2.7 Analisis Data

Data yang digunakan dalam sistem rekomendasi ini berupa data tekstual yang berasal dari dua entitas utama, yaitu mahasiswa dan faculty supervisor. Data mahasiswa mencakup informasi yang menggambarkan konteks posisi kerja, lingkungan perusahaan, serta deskripsi peran atau aktivitas yang dijalani mahasiswa. Informasi tersebut direpresentasikan dalam bentuk teks untuk mencerminkan karakteristik dan minat mahasiswa.

Data faculty supervisor mencakup informasi tekstual yang merepresentasikan karakteristik akademik dan pengalaman pembimbingan faculty supervisor, yang bersumber dari data historis dan informasi pendukung yang tersedia. Data historis tersebut digunakan sebagai referensi untuk membentuk representasi kompetensi masing-masing faculty supervisor.

Mengingat bentuk data yang digunakan bersifat dominan tekstual, pendekatan pencocokan berbasis kesesuaian makna melalui semantic similarity dinilai relevan untuk digunakan dalam sistem rekomendasi yang dikembangkan.

3.2.8 Perencanaan

Tahap perencanaan dilakukan setelah proses analisis untuk menyusun arah dan tahapan pengembangan sistem rekomendasi secara terstruktur. Tahap ini bertujuan untuk memastikan ruang lingkup penelitian, jenis data yang digunakan, serta pendekatan yang diterapkan selaras dengan tujuan penelitian.

Ruang lingkup penelitian dibatasi pada lingkungan XYZ dengan memanfaatkan data historis pasangan faculty supervisor dan mahasiswa pada tahun 2024. Selain data historis utama tersebut, tersedia data tambahan berupa informasi pendukung yang relevan, yang diperlakukan secara terpisah dan tidak menjadi acuan utama dalam proses evaluasi.

Perencanaan difokuskan pada pemanfaatan data tekstual yang berasal dari dua entitas utama, yaitu mahasiswa dan faculty supervisor, yang direpresentasikan dalam bentuk teks untuk mendukung proses pencocokan berbasis kesesuaian makna. Pendekatan yang direncanakan berfokus pada pengukuran semantic similarity antara profil mahasiswa dan dokumen faculty supervisor, yang selanjutnya digunakan sebagai dasar dalam proses perangkingan kandidat faculty supervisor.

Sistem dirancang sebagai decision support system yang digunakan oleh EPC sebagai administrator untuk membantu proses pengambilan keputusan pemetaan faculty supervisor dan mahasiswa, tanpa menggantikan keputusan akhir. Aplikasi berbasis website dikembangkan sebagai media implementasi metode yang diteliti.

Selain itu, tahap perencanaan mencakup rencana evaluasi terhadap hasil rekomendasi yang dihasilkan oleh sistem untuk menilai tingkat kesesuaian rekomendasi berdasarkan kriteria yang telah ditentukan. Apabila hasil evaluasi belum memenuhi kriteria yang diharapkan, dilakukan penyempurnaan terhadap representasi data atau parameter sistem tanpa melibatkan proses pelatihan atau fine-tuning model baru.

Sebagai batasan penelitian, sistem tidak dirancang sebagai layanan mandiri yang dapat diakses langsung oleh mahasiswa dan hanya memanfaatkan data yang tersedia pada periode penelitian yang telah ditetapkan.

3.2.9 Perancangan Model Rekomendasi Berbasis Semantic Similarity

Perancangan model rekomendasi pada penelitian ini bertujuan untuk menentukan mekanisme pencocokan antara mahasiswa dan faculty supervisor berdasarkan kesesuaian informasi tekstual. Model yang digunakan dalam sistem ini tidak melibatkan proses pelatihan training dari awal, melainkan memanfaatkan model text embedding open-source yang telah tersedia. Pendekatan ini dipilih untuk menghasilkan sistem rekomendasi yang efisien dan mudah diimplementasikan dalam konteks sistem informasi berbasis website.

3.2.10 Konsep Dasar Model Rekomendasi

Model rekomendasi dirancang menggunakan pendekatan semantic similarity, yaitu metode untuk mengukur tingkat kemiripan makna antara dua teks. Dalam penelitian ini, semantic similarity digunakan untuk membandingkan informasi tekstual mahasiswa dengan dokumen faculty supervisor sehingga sistem dapat menghasilkan rekomendasi dosen dengan tingkat kesesuaian tertinggi.

Informasi tekstual mahasiswa meliputi deskripsi posisi kerja, peran, nama perusahaan, serta kategori perusahaan. Sementara itu, informasi faculty supervisor direpresentasikan dalam beberapa dokumen teks yang menggambarkan karakteristik dan keahlian dosen berdasarkan data historis bimbingan serta informasi topik yang tersedia. Dokumen-dokumen tersebut dikelompokkan berdasarkan jenis sumber, sedangkan rincian sumber dan format penyusunan dokumen dijelaskan pada Subbab 3.2.3.2.

Hasil akhir dari proses rekomendasi adalah pasangan mahasiswa dan faculty supervisor yang dipilih berdasarkan peringkat kemiripan tertinggi dengan mempertimbangkan ketersediaan slot bimbingan dosen.

3.2.11 Pembentukan Representasi Data Faculty Supervisor

Setiap faculty supervisor direpresentasikan dalam bentuk satu atau lebih dokumen teks yang bersifat unik. Dokumen teks tersebut dibentuk dengan menggabungkan field-field tekstual dari masing-masing sumber data. Pada penelitian ini

terdapat dua sumber utama, yaitu data historis bimbingan faculty supervisor terhadap mahasiswa yang mencakup informasi posisi magang, perusahaan, dan deskripsi pekerjaan mahasiswa, serta data rekomendasi skripsi dari faculty supervisor yang mencakup topik skripsi, deskripsi skripsi, rumusan masalah, luaran yang diharapkan, dan jenis skripsi apabila tersedia.

Dokumen teks yang telah terbentuk kemudian ditransformasikan ke dalam representasi numerik menggunakan model text embedding. Hasil transformasi berupa vektor embedding disimpan ke dalam basis data, dengan satu baris data merepresentasikan satu dokumen milik faculty supervisor. Kumpulan embedding ini berfungsi sebagai knowledge base yang digunakan sebagai referensi utama dalam proses perhitungan kemiripan dan perbandingan rekomendasi.

Tabel 3.3. Tabel 3. Representasi Data Faculty Supervisor

Entitas	Atribut	Sumber	Deskripsi Singkat
Faculty supervisor	Informasi posisi magang	Data historis	Informasi posisi magang mahasiswa yang pernah dibimbing
		Enrichment	
Faculty supervisor	Perusahaan	Data historis	Informasi perusahaan mahasiswa yang pernah dibimbing
		Enrichment	
Faculty supervisor	Deskripsi pekerjaan mahasiswa	Data historis	Deskripsi bagian pekerjaan mahasiswa yang pernah dibimbing
		Enrichment	
Faculty supervisor	Topik skripsi	Data	Judul dan topik skripsi yang direkomendasi
		Rekomendasi	
		Skripsi Dari	
		Faculty Supervisor	

Entitas	Atribut	Sumber	Deskripsi Singkat
Faculty supervisor	Deskripsi skripsi	Data Rekomendasi Skripsi Dari Faculty Supervisor	Ringkasan deskripsi dan ruang lingkup penelitian
Faculty supervisor	Rumusan masalah	Data Rekomendasi Skripsi Dari Faculty Supervisor	Fokus permasalahan penelitian
Faculty supervisor	Luaran yang diharapkan	Data Rekomendasi Skripsi Dari Faculty Supervisor	Output akademik atau implementasi yang ditargetkan
Faculty supervisor	Jenis skripsi	Data Rekomendasi Skripsi Dari Faculty Supervisor	Klasifikasi jenis skripsi

Dalam implementasinya, apabila seorang faculty supervisor tidak memiliki data pada salah satu sumber, maka dokumen dari sumber tersebut tidak dibentuk. Dengan demikian, faculty supervisor tersebut tetap dapat direpresentasikan menggunakan dokumen yang tersedia, sehingga jumlah dokumen per faculty supervisor dapat berbeda-beda tergantung kelengkapan data.

3.2.12 Pemrosesan Data Mahasiswa

Data mahasiswa yang dimasukkan oleh EPC melalui sistem mencakup informasi posisi kerja, peran, dan nama perusahaan. Seluruh informasi tersebut digabungkan menjadi satu teks input dengan pemisah berupa whitespace untuk merepresentasikan karakteristik mahasiswa secara menyeluruh. Urutan penggabungan field ditetapkan secara konsisten, yaitu posisi kerja, peran, kemudian perusahaan. Apabila terdapat field yang tidak tersedia, field tersebut tidak disertakan tanpa mengubah urutan penggabungan.

Teks input mahasiswa selanjutnya diproses menggunakan model text embedding yang sama dengan yang digunakan pada data faculty supervisor, sehingga dihasilkan vektor embedding mahasiswa yang berada pada ruang representasi yang sama. Kondisi ini memungkinkan sistem melakukan perhitungan kemiripan secara langsung antara vektor embedding mahasiswa dan vektor embedding dokumen faculty supervisor. Selain itu, atribut status eligible digunakan sebagai filter kelayakan mahasiswa sebelum proses rekomendasi dan alokasi dosen dilakukan.

Tabel 3.4. Tabel 3. Pemrosesan Data Mahasiswa

Entitas	Atribut	Digunakan	
		sebagai Teks	Deskripsi
Mahasiswa	Identitas mahasiswa	Tidak	Digunakan sebagai identifikasi data
Mahasiswa	Posisi mahasiswa	Ya	Posisi atau peran magang yang diminati
Mahasiswa	Perusahaan	Ya	Nama perusahaan tujuan atau pengalaman
Mahasiswa	Kategori perusahaan	Ya	Klasifikasi bidang industri perusahaan

Entitas	Atribut	Digunakan sebagai Teks	Deskripsi
Mahasiswa	Status eligible	Tidak	Digunakan sebagai filter kelayakan mahasiswa

3.2.13 Alur Pemrosesan Data

Pipeline sistem terdiri dari delapan tahap berurutan, dimulai dari impor data Excel oleh EPC hingga ekspor hasil rekomendasi.

Tahap 1 Impor Data Excel. EPC mengunggah file Excel data mahasiswa melalui antarmuka web. Modul `excel_io.py` membersihkan dan menormalisasi setiap kolom, lalu menyimpan hasilnya ke tabel `students` dengan mekanisme *upsert*.

Tahap 2 Pembangunan Dokumen Teks. Modul `rules.py` mengubah data basis data menjadi representasi teks. Dokumen mahasiswa adalah gabungan posisi kerja, peran, dan nama perusahaan. Dokumen faculty supervisor berasal dari kata kunci kompetensi di basis data; bila fitur *extra docs* diaktifkan, dokumen diperkaya dengan data historis bimbingan dan rekomendasi skripsi.

Tahap 3 Generasi Embedding dan Perhitungan Similaritas. Modul `embedding.py` mengubah semua dokumen menjadi vektor embedding dengan model yang sama. Urutan *fallback*: *SentenceTransformer* (utama) → TF-IDF → *token overlap*. Embedding dinormalisasi L2, lalu *cosine similarity* dihitung untuk setiap pasang mahasiswa–faculty supervisor, menghasilkan matriks kemiripan $N \times M$.

Tahap 4 Penyusunan Skor Hybrid. Skor akhir adalah matriks kemiripan dikalikan bobot (default 1,0), ditambah *company group bonus* bila diaktifkan. Bonus mendorong mahasiswa se-perusahaan ke faculty supervisor yang sama, dengan tiga syarat: minimal dua mahasiswa se-perusahaan, diversitas topik ≤ 6 token, dan selisih skor dua dosen terbaik $\geq 0,08$. Nilai bonus menurun secara logaritmik seiring besarnya kelompok.

Tahap 5 Perencanaan Kapasitas. Kapasitas setiap faculty supervisor ditetapkan pada rentang 10–12 mahasiswa. Bila total mahasiswa melebihi total kapasitas

maksimum (*overflow*), slot tambahan dialokasikan ke dosen berprioritas terlebih dahulu, lalu *round-robin*. Bila kurang dari total minimum (*underflow*), batas minimum dikurangi dari dosen berprioritas terendah.

Tahap 6 Penugasan *Greedy*. Algoritma *greedy* dua fase menyelesaikan penugasan. Inisialisasi: tiap mahasiswa ke faculty supervisor dengan skor tertinggi (*argmax*). Fase 1 memindahkan mahasiswa dari dosen kelebihan kapasitas ke yang masih kosong, memilih pemindahan dengan penalti skor terkecil. Fase 2 mengisi dosen yang belum mencapai batas minimum dengan cara serupa. Jika setelah iterasi maksimum masih ada pelanggaran kapasitas, sistem melempar *RuntimeError*.

Tahap 7 Evaluasi. Evaluasi dijalankan tiga kali: dari matriks kemiripan konten, matriks skor *hybrid*, dan hasil penugasan akhir. Ketiganya dibandingkan terhadap *ground truth* (`current_supervisor_code`) menggunakan metrik MRR, Hit@1, Hit@5, NDCG@5, NDCG@10, *Precision@5*, dan *Match Rate*.

Tahap 8 Penyimpanan dan Ekspor. Hasil pipeline disimpan ke tabel `recommendation_runs` dan `recommendations`. Top-5 kandidat beserta skor tiap mahasiswa tersimpan sebagai JSON di kolom `rankings_json`. EPC mengunduh hasil dalam dua format Excel: ekspor standar (3 *sheet*: rekomendasi, kapasitas, evaluasi) atau ekspor *detailed* (4 *sheet*, ditambah peringkat kandidat per mahasiswa).

3.2.14 Kandidat Model Text Embedding

Pada penelitian ini, vektor embedding dibentuk menggunakan model text embedding open-source tanpa proses pelatihan ulang fine-tuning. Pemilihan kandidat model mempertimbangkan kebutuhan sistem yang menggunakan representasi dosen dalam bentuk multi-dokumen per jenis sumber, serta karakteristik data yang berpotensi memuat istilah campuran Bahasa Indonesia–Inggris. Seluruh kandidat model akan digunakan dengan mekanisme yang konsisten: teks mahasiswa dan dokumen faculty supervisor diubah menjadi embedding menggunakan model yang sama, kemudian dihitung kemiripannya menggunakan cosine similarity. Embedding yang dihasilkan digunakan apa adanya sesuai keluaran model tanpa normalisasi manual tambahan pada tahap pra-pemrosesan, dan sistem menghasilkan rekomendasi top-5

dosen sebelum tahap alokasi slot bimbingan.

3.2.15 Qwen3-Embedding-0.6B

Qwen3-Embedding-0.6B merupakan model embedding berukuran sekitar 0,6B parameter yang dirancang untuk tugas representasi teks dan retrieval. Model ini mendukung panjang konteks hingga 32K token, sehingga relevan untuk dokumen dosen yang berpotensi panjang, terutama ketika dokumen historis bimbingan dan dokumen rekomendasi skripsi memiliki konten yang kaya.

Selain itu, seri Qwen3 Embedding mendukung Matryoshka Representation Learning (MRL) yang memungkinkan penggunaan dimensi embedding yang fleksibel misalnya rentang 32–1024 untuk menyeimbangkan kualitas dan efisiensi penyimpanan/komputasi.

3.2.16 BAAI/bge-m3

BAAI/bge-m3 merupakan model embedding multibahasa dari Beijing Academy of Artificial Intelligence (BAAI) yang dirancang untuk mendukung tiga mekanisme *retrieval* sekaligus: *dense retrieval*, *sparse retrieval*, dan *multi-vector retrieval*. Model ini mendukung lebih dari 100 bahasa dan memiliki kapasitas konteks hingga 8.192 token, sehingga relevan untuk dokumen dosen yang berpotensi panjang.

Pada penelitian ini, BAAI/bge-m3 digunakan dalam mode *dense retrieval*, yaitu menghasilkan satu vektor embedding per dokumen yang kemudian dihitung kemiripannya menggunakan *cosine similarity*. Model ini dipilih sebagai kandidat karena kemampuan multilingual dan kapasitas konteks yang memadai untuk merepresentasikan dokumen profil dosen dengan konten campuran Bahasa Indonesia–Inggris.

3.2.17 intfloat/multilingual-e5-large-instruct

intfloat/multilingual-e5-large-instruct merupakan model embedding multibahasa berbasis arsitektur XLM-RoBERTa yang dikembangkan oleh Microsoft sebagai bagian dari seri E5 (*Embeddings from bidirectional Encoder representations*). Model ini mendukung lebih dari 100 bahasa dengan dimensi embedding 1.024 dan

kapasitas konteks hingga 512 token.

Keunggulan utama model ini terletak pada kemampuan *instruction-following*, di mana teks *query* dan *passage* direpresentasikan dengan awalan instruksi yang berbeda untuk memisahkan konteks pencarian dari dokumen yang diindeks. Model ini ditetapkan sebagai model *default* dalam sistem karena keseimbangan antara kualitas *retrieval* multibahasa dan efisiensi komputasi pada perangkat tanpa GPU khusus.

3.2.18 Keterkaitan Kandidat Model dengan Mekanisme Rekomendasi

Ketiga kandidat model dipilih untuk dibandingkan pada *pipeline* yang sama, sehingga perbedaan kinerja dapat dikaitkan dengan karakteristik masing-masing model, bukan perbedaan perlakuan data. Qwen3-Embedding-0.6B menawarkan kapasitas konteks terpanjang (32K token) dengan ukuran parameter paling ringan, BAAI/bge-m3 menyediakan kapasitas konteks menengah (8K token) dengan arsitektur multi-retrieval, sedangkan intfloat/multilingual-e5-large-instruct memiliki kapasitas konteks lebih terbatas (512 token) namun dioptimalkan untuk tugas *instruction-following retrieval*. Perbandingan ketiga model ini memungkinkan analisis terhadap pengaruh kapasitas konteks dan pendekatan *fine-tuning* terhadap kualitas rekomendasi dalam konteks data campuran Bahasa Indonesia–Inggris.

Sebagai transisi ke Subbab 3.2.3.7, penentuan model terbaik dilakukan melalui strategi evaluasi yang mengukur kualitas rekomendasi top-5 serta mempertimbangkan aspek efisiensi komputasi pada saat inferensi embedding.

3.2.19 Mekanisme Perhitungan dan Perangkingan Rekomendasi

Setelah vektor embedding mahasiswa dan dokumen faculty supervisor tersedia, sistem melakukan perhitungan tingkat kemiripan antara embedding mahasiswa dan seluruh embedding dokumen faculty supervisor yang tersimpan dalam knowledge base. Perhitungan kemiripan dilakukan menggunakan cosine similarity, yang mengukur kedekatan arah antara dua vektor pada ruang embedding.

Karena setiap faculty supervisor direpresentasikan oleh beberapa dokumen teks

yang berasal dari jenis sumber yang berbeda, perhitungan kemiripan dilakukan pada tingkat dokumen. Selanjutnya, nilai kemiripan pada tingkat dokumen diagregasi menjadi skor pada tingkat faculty supervisor. Agregasi dilakukan dengan mengambil nilai kemiripan maksimum dari seluruh dokumen yang dimiliki oleh faculty supervisor tersebut. Pendekatan ini dipilih karena setiap dokumen merepresentasikan aspek kompetensi yang berbeda, sehingga kecocokan tinggi pada salah satu aspek dianggap cukup untuk menunjukkan relevansi awal antara mahasiswa dan faculty supervisor.

Berdasarkan skor akhir tersebut, sistem melakukan pengurutan faculty supervisor dari tingkat kesesuaian tertinggi hingga terendah untuk setiap mahasiswa. Hasil dari proses ini berupa daftar rekomendasi top-5 faculty supervisor yang selanjutnya digunakan sebagai input pada tahap validasi dan alokasi slot bimbingan yang dijelaskan pada Subbab 3.2.3.6.

Struktur data knowledge base yang digunakan dalam proses perhitungan kemiripan dan perangkingan ditunjukkan pada Tabel berikut.

Tabel 3.5. Tabel 3. Struktur Data Knowledge Base

Kolom	Deskripsi
faculty_supervisor_id	Identitas unik faculty supervisor
document_id	Identitas dokumen
document_source_type	Jenis sumber dokumen (Data Historis Mahasiswa / Topik Skripsi)
document_text	Hasil penggabungan seluruh atribut tekstual
vector_embedding	Representasi vektor dari dokumen teks

3.2.20 Validasi Slot Bimbingan faculty supervisor

Selain mempertimbangkan tingkat kesesuaian berdasarkan semantic similarity, sistem juga melakukan validasi terhadap ketersediaan slot bimbingan faculty supervisor. Proses validasi ini dilakukan setelah tahap perangkingan selesai dan bertujuan untuk memastikan bahwa rekomendasi yang dihasilkan dapat direalisasikan sesuai dengan kapasitas bimbingan yang tersedia.

Alokasi dilakukan secara batch terhadap seluruh mahasiswa yang memenuhi kriteria *eligible* menggunakan algoritma *greedy* dua fase. Sebelum fase alokasi dijalankan, sistem menyusun rencana kapasitas (*capacity plan*) yang menentukan batas minimum dan maksimum jumlah mahasiswa per faculty supervisor berdasarkan total mahasiswa dan jumlah supervisor aktif. Parameter `target_min` dan `target_max` menjadi acuan awal, dengan penyesuaian otomatis apabila total mahasiswa melebihi atau di bawah kapasitas kolektif (*overflow/underflow*).

Algoritma *greedy* dua fase bekerja sebagai berikut:

1. **Inisialisasi:** Setiap mahasiswa dialokasikan ke faculty supervisor dengan skor tertinggi (*argmax*) tanpa mempertimbangkan kapasitas.
2. **Fase 1 — Pengurangan *Overfull*:** Sistem secara iteratif memindahkan mahasiswa dari supervisor yang melebihi batas maksimum ke supervisor lain yang masih tersedia, dengan memilih pemindahan yang menghasilkan *penalty* skor terkecil.
3. **Fase 2 — Pengisian *Underfull*:** Sistem secara iteratif memindahkan mahasiswa dari supervisor yang berada di atas batas minimum (*donor*) ke supervisor yang berada di bawah batas minimum, kembali dengan memilih pemindahan dengan *penalty* terkecil.

Setelah kedua fase selesai, sistem melakukan validasi akhir untuk memastikan seluruh constraint kapasitas terpenuhi. Apabila validasi gagal, sistem menghentikan proses dan menampilkan pesan kesalahan kepada EPC. Hasil akhir berupa pasangan mahasiswa dan faculty supervisor yang memenuhi seluruh batasan kapasitas secara optimal.

3.2.21 Strategi evaluasi

Strategi evaluasi pada penelitian ini dirancang untuk menilai efektivitas model rekomendasi berbasis semantic similarity dalam menghasilkan pasangan mahasiswa dan faculty supervisor yang relevan. Evaluasi difokuskan pada dua aspek utama, yaitu kualitas hasil perangkingan rekomendasi dan dampak penerapan validasi slot bimbingan terhadap hasil akhir alokasi.

Evaluasi kualitas perangkingan dilakukan dengan membandingkan hasil rekomendasi yang dihasilkan sistem terhadap data *ground truth* yang tersedia, berupa pasangan mahasiswa–*faculty supervisor* dari data historis penugasan. Metrik evaluasi yang digunakan adalah metrik *information retrieval* berbasis peringkat, yaitu:

- **MRR** (*Mean Reciprocal Rank*): rata-rata nilai kebalikan posisi *faculty supervisor ground truth* dalam daftar rekomendasi, mengukur seberapa tinggi posisi rekomendasi yang relevan secara keseluruhan.
- **Hit@1** dan **Hit@5**: proporsi mahasiswa yang *faculty supervisor ground truth*-nya muncul pada posisi pertama atau dalam lima rekomendasi teratas.
- **NDCG@5** dan **NDCG@10**: *Normalized Discounted Cumulative Gain* dengan cutoff 5 dan 10, mengukur kualitas urutan rekomendasi dengan pembobotan logaritmik berdasarkan posisi.
- **Avg Rank**: rata-rata posisi *faculty supervisor ground truth* dalam daftar rekomendasi yang dihasilkan.

Evaluasi dilakukan secara konsisten untuk seluruh kandidat model *text embedding* dengan menerapkan *pipeline* yang sama, meliputi pembentukan dokumen *faculty supervisor*, pemrosesan teks mahasiswa, perhitungan *cosine similarity*, serta pembentukan daftar rekomendasi. Dengan demikian, perbandingan kinerja antar model mencerminkan perbedaan karakteristik model *embedding*, bukan perbedaan perlakuan data.

Selain evaluasi perangkingan, penelitian ini juga mengevaluasi hasil alokasi akhir yang dihasilkan oleh *greedy solver*. Metrik yang digunakan adalah **Assignment Match Rate**, yaitu proporsi mahasiswa yang *faculty supervisor* hasil alokasi

sistem sesuai dengan data penugasan historis. Metrik ini mengukur keselarasan antara keluaran sistem secara *end-to-end* (termasuk batasan kapasitas) dengan praktik pemetaan yang telah berjalan.


Berdasarkan hasil evaluasi tersebut, model *text embedding* yang memberikan kinerja terbaik dalam menghasilkan rekomendasi yang relevan dipilih sebagai model yang digunakan pada sistem rekomendasi yang diusulkan.

3.2.22 Perancangan UML

Perancangan UML dan use case pada penelitian ini bertujuan untuk memodelkan alur interaksi sistem sebagai decision support system bagi EPC. Diagram yang disusun tidak dimaksudkan untuk menggambarkan sistem produksi secara menyeluruh, melainkan untuk memastikan bahwa proses pengolahan data dan pemanggilan metode semantic similarity berjalan sesuai dengan kebutuhan penelitian dan skenario evaluasi.

3.2.23 Use Case Diagram

Use Case Diagram memberikan ilustrasi tentang proses-proses yang berlangsung dalam Sistem Rekomendasi *Faculty Supervisor* yang dikembangkan. Diagram ini menggambarkan aktor yang berinteraksi dengan sistem beserta fungsionalitas yang tersedia. Aktor utama dalam sistem ini adalah **EPC**, yaitu koordinator program studi yang menggunakan sistem untuk mengelola data mahasiswa, mengonfigurasi profil *faculty supervisor*, menjalankan proses rekomendasi, serta menganalisis dan mengekspor hasilnya.



Gambar 3.2. Use Case Diagram Sistem Rekomendasi Faculty Supervisor

3.2.24 Use Case Narrative

Use case narrative disusun untuk memberikan penjelasan rinci mengenai alur interaksi antara aktor dan sistem rekomendasi yang diusulkan. Narasi ini melengkapi use case diagram dengan mendeskripsikan setiap skenario penggunaan sistem secara lebih detail, termasuk tujuan use case, aktor yang terlibat, prasyarat, alur utama, serta kondisi pengecualian yang mungkin terjadi.

Perancangan use case narrative mengacu pada proses bisnis dan alur fungsional sistem yang telah dijelaskan pada Subbab 3.2.3, khususnya terkait penginputan data mahasiswa oleh EPC, proses pembentukan embedding, perhitungan kemiripan, perbandingan faculty supervisor, serta validasi slot bimbingan. Dengan demikian, use case narrative berfungsi sebagai penghubung antara perancangan konseptual sistem dan kebutuhan fungsional yang harus dipenuhi oleh sistem pada tahap implementasi.

Melalui use case narrative, setiap fungsi utama sistem dijabarkan secara sistematis sehingga dapat memberikan pemahaman yang jelas mengenai bagaimana sistem merespons aksi pengguna dalam berbagai kondisi. Narasi ini juga membantu memastikan bahwa seluruh kebutuhan fungsional yang telah dirancang dapat ditelusuri secara konsisten dari tahap analisis kebutuhan hingga perancangan dan implementasi sistem.

Tabel 3.6. Tabel 3.6 Use Case Register

Elemen	Deskripsi	
Use Case Name	Register	
Scenario	EPC membuat akun baru untuk mengakses sistem rekomendasi	
Triggering Events	EPC membuka halaman registrasi	
Brief Description	Use case ini menggambarkan proses pembuatan akun baru oleh EPC yang mencakup pengisian username, nama lengkap, dan password	
Actor	EPC	
Related Use Case	Login	
Stakeholder	EPC	
Pre-condition	Sistem dalam kondisi aktif, EPC belum memiliki akun	
Post-condition	Akun EPC tersimpan di database dengan password ter-hash (PBKDF2); EPC diarahkan ke halaman Login untuk melakukan autentikasi	
Flow Of Events	Actor	System
	EPC membuka halaman registrasi	Sistem menampilkan formulir registrasi (username, nama lengkap, password, konfirmasi password)
	EPC mengisi formulir dan menekan tombol Register	Sistem memvalidasi bahwa password dan konfirmasi password sesuai

		Sistem memeriksa ketersediaan username
		Sistem menyimpan akun baru dengan password ter-hash
Exception Condition	Condition	Handling
	Password dan konfirmasi password tidak sama	Sistem menampilkan pesan kesalahan dan meminta EPC mengulang
	Username sudah digunakan	Sistem menampilkan pesan kesalahan
	Username kurang dari 3 karakter	Sistem menolak registrasi
	Password kurang dari 6 karakter	Sistem menolak registrasi

Tabel 3.7. Tabel 3.7 Use Case Login

Elemen	Deskripsi	
Use Case Name	Login	
Scenario	EPC melakukan autentikasi untuk mengakses sistem	
Triggering Events	EPC membuka halaman login	
Brief Description	Use case ini menggambarkan proses autentikasi EPC menggunakan username dan password	
Actor	EPC	
Related Use Case	Register, seluruh use case yang memerlukan login	
Stakeholder	EPC	
Pre-condition	EPC telah memiliki akun terdaftar	
Post-condition	EPC berhasil login dan dapat mengakses seluruh fitur sistem	
Flow Of Events	Actor	System

	EPC membuka halaman login	Sistem menampilkan formulir login (username, password)
	EPC mengisi username dan password, lalu menekan tombol Login	Sistem menormalisasi username (lowercase, strip whitespace) sebelum melakukan pencarian di database
		Sistem memvalidasi kredensial terhadap database
		Sistem membuat session dan mengarahkan ke halaman Dashboard (atau URL aman sebelumnya)
Exception Condition	Condition	Handling
	Username atau password salah	Sistem menampilkan pesan "Username atau password salah"
	Username tidak ditemukan	Sistem menampilkan pesan kesalahan yang sama (tanpa membedakan username/password yang salah)

Tabel 3.8. Tabel 3.8 Use Case Import Data Mahasiswa

Elemen	Deskripsi
Use Case Name	Import Data Mahasiswa
Scenario	EPC mengimpor data mahasiswa dari file Excel ke dalam sistem
Triggering Events	EPC membuka menu Data Center dan memilih opsi import

Brief Description	Use case ini menggambarkan proses pengunggahan file Excel yang berisi data mahasiswa, termasuk validasi format dan penyimpanan ke database	
Actor	EPC	
Related Use Case	Trigger Proses Rekomendasi	
Stakeholder	EPC, Program Studi	
Pre-condition	EPC telah login; file Excel berformat .xlsx dengan kolom wajib: STUDENT ID, TRACK, PARTNER/LECTURER, POSITION/TOPIC, WORK SCHEMA, GPA	
Post-condition	Data mahasiswa tersimpan di database; data siap diproses oleh sistem rekomendasi	
Flow Of Events	Actor	System
	EPC membuka halaman Data Center	Sistem menampilkan halaman Data Center dengan opsi import (default path atau upload)
	EPC memilih file Excel dan menekan tombol Import	Sistem membaca file Excel dan memvalidasi keberadaan kolom wajib
		Sistem melakukan normalisasi data (pembersihan ID, konversi tipe data)
		Sistem melakukan upsert data ke tabel students (insert baru atau update existing)
		Sistem menampilkan notifikasi berisi jumlah inserted, updated, dan total
Exception Condition	Condition	Handling

	File bukan format .xlsx	Sistem menolak file dan menampilkan pesan kesalahan
	Kolom wajib tidak ditemukan	Sistem menampilkan pesan kesalahan dengan daftar kolom yang hilang
	Gagal membaca file	Sistem menampilkan pesan kegagalan

Tabel 3.9. Tabel 3.9 Use Case Kelola Data Faculty Supervisor

Elemen	Deskripsi	
Use Case Name	Kelola Data Faculty Supervisor	
Scenario	EPC mengelola data faculty supervisor termasuk profil dan keywords	
Triggering Events	EPC membuka menu Supervisor Studio	
Brief Description	Use case ini menjelaskan proses pengelolaan data profil faculty supervisor, termasuk penambahan supervisor baru, pembaruan nama dan status aktif, serta ekspor konfigurasi supervisor ke file Excel	
Actor	EPC	
Related Use Case	Trigger Proses Rekomendasi	
Stakeholder	EPC, Faculty Supervisor	
Pre-condition	EPC telah login ke sistem	
Post-condition	Data faculty supervisor tersimpan dan diperbarui	
Flow Of Events	Actor	System
	EPC membuka halaman Supervisor Studio	Sistem menampilkan daftar faculty supervisor aktif beserta keywords masing-masing

	EPC memilih faculty supervisor untuk diedit atau menambahkan faculty supervisor baru	Sistem menampilkan formulir detail (kode, nama)
	EPC mengisi atau memperbarui data dan menekan tombol Simpan	Sistem memvalidasi dan menyimpan perubahan
	EPC dapat mengekspor konfigurasi ke Excel	Sistem menghasilkan file Excel berisi daftar supervisor dan track reference
Exception Condition	Condition	Handling
	Nama supervisor sudah digunakan oleh kode lain	Sistem menampilkan pesan konflik (UNIQUE constraint pada kolom name)
	Kode supervisor atau nama kosong	Sistem menampilkan pesan validasi
	EPC belum login (session expired)	Sistem mengarahkan EPC ke halaman login secara otomatis

Tabel 3.10. Tabel 3.10 Use Case Kelola Keywords Supervisor

Elemen	Deskripsi
Use Case Name	Kelola Keywords Supervisor
Scenario	EPC mengelola keyword kompetensi masing-masing faculty supervisor melalui Keywords Studio
Triggering Events	EPC memilih supervisor dan membuka Keywords Studio di halaman Supervisors

Brief Description	Use case ini menjelaskan proses penambahan, pengeditan, dan penghapusan keyword kompetensi faculty supervisor menggunakan antarmuka chip berbasis token (Keywords Studio). Keyword yang tersimpan digunakan sebagai profil supervisor dalam pipeline rekomendasi.	
Actor	EPC	
Related Use Case	Kelola Data Faculty Supervisor, Trigger Proses Rekomendasi	
Stakeholder	EPC, Faculty Supervisor	
Pre-condition	EPC telah login; data faculty supervisor telah tersedia di sistem	
Post-condition	Keyword supervisor tersimpan di kolom <code>profile_keywords</code> pada tabel <code>supervisors</code> ; profil siapa digunakan pada run rekomendasi berikutnya	
Flow Of Events	Actor	System
	EPC membuka halaman Supervisors dan memilih supervisor dari dropdown	Sistem menampilkan chip keyword yang sudah tersimpan untuk supervisor tersebut
	EPC mengetik keyword baru di input field	
	EPC menekan Enter, Comma, atau tombol Add	Sistem menormalisasi token (trim, collapse whitespace) dan melakukan pengecekan duplikasi (case-insensitive)
		Jika bukan duplikat: Sistem menambahkan chip keyword baru ke tampilan
	EPC menghapus chip keyword yang tidak relevan (klik ×)	Sistem menghapus keyword dari tampilan sementara

	EPC menekan tombol Save	Sistem menggabungkan semua keyword aktif menjadi string comma-separated dan menyimpan ke kolom <code>profile.keywords</code> di database
		Sistem menampilkan konfirmasi berhasil
Exception Condition	Condition	Handling
	Keyword yang ditambahkan sudah ada (duplikat, case-insensitive)	Sistem mengabaikan token duplikat dan tidak menambahkan chip baru
	Supervisor tidak ditemukan saat simpan	Sistem menampilkan pesan kesalahan
	EPC belum login (session expired)	Sistem mengarahkan EPC ke halaman login secara otomatis

Tabel 3.11. Tabel 3.11 Use Case Trigger Proses Rekomendasi

Elemen	Deskripsi
Use Case Name	Trigger Proses Rekomendasi
Scenario	EPC menjalankan proses rekomendasi untuk mengalokasikan mahasiswa ke faculty supervisor
Triggering Events	EPC menekan tombol Generate Recommendation
Brief Description	Use case ini menggambarkan proses inisiasi pipeline rekomendasi lengkap: embedding → similarity → group bonus → capacity planning → greedy solver → evaluasi
Actor	EPC

Related Use Case	Import Data Mahasiswa, Kelola Data Faculty Supervisor, Kelola Keywords Supervisor	
Stakeholder	EPC, Program Studi	
Pre-condition	Data mahasiswa telah diimpor; data faculty supervisor telah tersedia; EPC telah login	
Post-condition	Hasil rekomendasi (run) tersimpan di database dengan evaluasi metrik	
Flow Of Events	Actor	System
	EPC memilih model embedding yang akan digunakan	Sistem menampilkan opsi konfigurasi (model, enable/disable group bonus, capacity parameters)
	EPC mengonfigurasi parameter dan menekan tombol Generate	Sistem memvalidasi ketersediaan data mahasiswa dan dosen
		Sistem membentuk dokumen teks mahasiswa dan faculty supervisor
		Sistem memperkaya profil supervisor secara adaptif dari histori assignment mahasiswa sebelumnya (adaptive profile enrichment)
		Sistem mengencode dokumen menggunakan model embedding yang dipilih
		Sistem menghitung cosine similarity matrix

		Jika parameter group bonus diaktifkan (enable_group_bonus = true), sistem menerapkan Company Group Bonus pada score matrix berdasarkan pengelompokan company partner mahasiswa
		Sistem menghitung capacity plan (min/max per supervisor)
		Sistem menjalankan greedy solver untuk alokasi optimal
		Sistem menghitung metrik evaluasi (content-based dan hybrid)
		Sistem membangun rankings JSON (top-5 kandidat per mahasiswa beserta skor)
		Sistem menyimpan hasil run dan mengarahkan ke halaman detail run
Exception Condition	Condition	Handling
	Data mahasiswa belum di-impor	Sistem menolak proses dan menampilkan notifikasi
	Data faculty supervisor tidak tersedia	Sistem menolak proses dan menampilkan notifikasi
	Greedy solver gagal menemukan solusi	Sistem menampilkan pesan kesalahan

	Model SentenceTransformer tidak tersedia atau gagal dimuat	Sistem menggunakan fallback ke TF-IDF; jika TF-IDF juga gagal, sistem menggunakan Token Overlap (Jaccard coefficient)
--	--	---

Tabel 3.12. Tabel 3.12 Use Case Lihat Riwayat Run

Elemen	Deskripsi	
Use Case Name	Lihat Riwayat Run	
Scenario	EPC menelusuri seluruh riwayat eksekusi proses rekomendasi yang pernah dilakukan	
Triggering Events	EPC membuka menu Runs atau memilih tautan riwayat dari Dashboard	
Brief Description	Use case ini menggambarkan proses penelusuran daftar run rekomendasi yang tersimpan di database, meliputi informasi ringkasan setiap run (waktu, jumlah mahasiswa, objective score, match rate) serta navigasi menuju detail run tertentu	
Actor	EPC	
Related Use Case	Trigger Proses Rekomendasi, Lihat Hasil Rekomendasi	
Stakeholder	EPC, Program Studi	
Pre-condition	EPC telah login ke sistem	
Post-condition	EPC memperoleh daftar seluruh run dan dapat memilih run untuk dilihat detailnya	
Flow Of Events	Actor	System
	EPC membuka halaman Riwayat Run (/runs)	Sistem mengambil hingga 250 run terbaru dari database, diurutkan berdasarkan waktu terbaru

		Sistem menampilkan tabel riwayat run (Run ID, tanggal eksekusi, jumlah mahasiswa, jumlah supervisor, objective score, match rate, embedding model)
	EPC memilih run yang ingin dilihat detailnya	Sistem mengarahkan ke halaman detail run (/runs/{id})
Exception Condition	Condition	Handling
	Belum ada run yang pernah dilakukan	Sistem menampilkan tabel kosong dengan informasi bahwa belum ada run tersedia
	EPC belum login (session expired)	Sistem mengarahkan EPC ke halaman login secara otomatis

Tabel 3.13. Tabel 3.13 Use Case Lihat Hasil Rekomendasi

Elemen	Deskripsi
Use Case Name	Lihat Hasil Rekomendasi
Scenario	EPC melihat detail hasil rekomendasi suatu run
Triggering Events	EPC membuka halaman detail run atau halaman rekomendasi
Brief Description	Use case ini menggambarkan proses penelusuran hasil rekomendasi termasuk evaluasi metrik, distribusi kapasitas, daftar mismatch, dan detail per mahasiswa
Actor	EPC
Related Use Case	Trigger Proses Rekomendasi, Lihat Riwayat Run, Export Hasil ke Excel
Stakeholder	EPC, Program Studi

Pre-condition	Minimal satu run rekomendasi telah berhasil dilakukan; EPC telah memilih run dari daftar riwayat	
Post-condition	EPC memperoleh informasi detail hasil rekomendasi	
Flow Of Events	Actor	System
	EPC membuka halaman detail run	Sistem menampilkan evaluasi metrik (content-based & hybrid), distribusi kapasitas per supervisor, dan daftar mismatch
	EPC membuka halaman rekomendasi	Sistem menampilkan tabel seluruh pasangan mahasiswa-supervisor dengan skor, rule matches, dan filter pencarian
	EPC menggunakan filter (nama, supervisor, mismatch only)	Sistem memfilter dan menampilkan hasil sesuai kriteria
Exception Condition	Condition	Handling
	Run ID tidak ditemukan di database	Sistem menampilkan pesan kesalahan "Run {run_id} tidak ditemukan"
	Tidak ada data rekomendasi pada run yang dipilih	Sistem menampilkan halaman detail run dengan tabel rekomendasi kosong
	Filter pencarian tidak menghasilkan kecocokan	Sistem menampilkan tabel kosong dengan informasi jumlah hasil 0 dari total keseluruhan
	EPC belum login (session expired)	Sistem mengarahkan EPC ke halaman login secara otomatis

Tabel 3.14. Tabel 3.14 Use Case Export Hasil ke Excel

Elemen	Deskripsi	
Use Case Name	Export Hasil ke Excel	
Scenario	EPC mengunduh hasil rekomendasi dalam format Excel	
Triggering Events	EPC menekan tombol Export Standard atau Export Detailed pada halaman detail run	
Brief Description	Sistem menghasilkan file Excel hasil rekomendasi dalam dua pilihan format: Standard Export (3 sheet: recommendations, summary, evaluation) atau Detailed Export (4 sheet: menambahkan sheet rankings berisi top-N kandidat per mahasiswa)	
Actor	EPC	
Related Use Case	Lihat Hasil Rekomendasi	
Stakeholder	EPC, Program Studi	
Pre-condition	EPC telah login, run rekomendasi telah tersedia	
Post-condition	File Excel berhasil diunduh oleh EPC	
Flow Of Events	Actor	System
	EPC membuka halaman detail run	Sistem menampilkan halaman detail run beserta tombol Export Excel
	EPC menekan tombol Export Standard	Sistem mengambil seluruh data rekomendasi dari run yang dipilih (pasangan mahasiswa-supervisor beserta skor similarity, group boost, final score, rule matches, dan company group key)

		Sistem mengambil data summary kapasitas per supervisor (jumlah mahasiswa yang dialokasikan, batas min/max kapasitas, dan status within capacity)
		Sistem mengambil data evaluasi metrik dari run (content-based metrics dan hybrid score metrics) dan mengonversinya menjadi format tabel (section, metric, value)
		Sistem membentuk file Excel (.xlsx) menggunakan engine openpyxl dengan 3 sheet: recommendations, summary, dan evaluation; mengirim sebagai attachment dengan nama rekomendasi_dosen_run_{run_id}.xlsx
	EPC menekan tombol Export Detailed (opsional)	Sistem mengambil data yang sama ditambah rankings JSON (top-N kandidat per mahasiswa) dan membentuk file Excel 4 sheet (recommendations, summary, evaluation, rankings) dengan nama rekomendasi_dosen_run_{run_id}_detailed.xlsx

	EPC menerima dan menyimpan file Excel	
Exception Condition	Condition	Handling
	Run ID tidak ditemukan di database	Sistem menampilkan pesan kesalahan "Run {run_id} tidak ditemukan" dan mengarahkan kembali ke halaman detail run
	Terjadi kegagalan saat pembuatan file Excel (misalnya data corrupt atau error engine openpyxl)	Sistem menampilkan flash message "Gagal export Excel: {pesan error}" dan mengarahkan kembali ke halaman detail run
	EPC belum login (session expired)	Sistem mengarahkan EPC ke halaman login secara otomatis

Tabel 3.15. Tabel 3.15 Use Case Logout

Elemen	Deskripsi
Use Case Name	Logout
Scenario	EPC mengakhiri sesi aktif pada sistem
Triggering Events	EPC menekan tombol Logout pada navigasi sistem
Brief Description	Use case ini menggambarkan proses penghapusan sesi autentikasi sehingga EPC tidak lagi dapat mengakses fitur-fitur sistem yang memerlukan login
Actor	EPC
Related Use Case	Login
Stakeholder	EPC
Pre-condition	EPC dalam kondisi telah login (memiliki sesi aktif)

Post-condition	Sesi EPC dihapus dari server, EPC diarahkan ke halaman login	
Flow Of Events	Actor	System
	EPC menekan tombol Logout pada navigasi	Sistem menerima request POST ke endpoint logout
		Sistem menghapus user_id dari session server
		Sistem menampilkan flash message "Logout berhasil"
		Sistem mengarahkan EPC ke halaman login
Exception Condition	Condition	Handling
	EPC mengakses fitur sistem setelah logout	Sistem mengarahkan EPC ke halaman login secara otomatis melalui mekanisme login_required
	Session sudah expired sebelum logout	Sistem tetap mengarahkan ke halaman login tanpa error

Tabel 3.16. Tabel 3.16 Use Case Lihat Dashboard


Elemen	Deskripsi
Use Case Name	Lihat Dashboard
Scenario	EPC melihat ringkasan kondisi sistem dan metrik kualitas rekomendasi
Triggering Events	EPC berhasil login atau membuka halaman Dashboard
Brief Description	Use case ini menggambarkan proses penampilan halaman utama (Command Center) yang menyajikan statistik ringkasan data, highlight metrik evaluasi dari run terakhir, konfigurasi pipeline aktif, serta daftar riwayat run terbaru

Actor	EPC	
Related Use Case	Login, Trigger Proses Rekomendasi, Lihat Hasil Rekomendasi	
Stakeholder	EPC, Program Studi	
Pre-condition	EPC telah login ke sistem	
Post-condition	EPC memperoleh gambaran umum kondisi terkini sistem rekomendasi	
Flow Of Events	Actor	System
	EPC membuka halaman Dashboard (atau diarahkan otomatis setelah login)	Sistem mengambil data run terakhir dari database
		Sistem mengambil daftar 12 run terbaru beserta metrik per run
		Sistem menghitung statistik ringkasan: total mahasiswa, jumlah faculty supervisor aktif, dan total run yang pernah dilakukan
		Sistem mengekstrak highlight metrics dari run terakhir: Assignment Match Rate, Hybrid MRR, dan Content-Based MRR
		Sistem mengekstrak konfigurasi pipeline dari run terakhir (model embedding, group bonus, extra docs, similarity weight)


		Sistem menampilkan seluruh informasi dalam halaman Dashboard (Command Center)
	EPC menelusuri informasi ringkasan dan metrik yang ditampilkan	
	EPC dapat memilih run dari daftar riwayat untuk melihat detail	Sistem mengarahkan ke halaman detail run yang dipilih
Exception Condition	Condition	Handling
	Belum ada run rekomendasi yang pernah dilakukan	Sistem tetap menampilkan Dashboard dengan statistik data (total mahasiswa, supervisor aktif) namun bagian metrik dan riwayat run ditampilkan kosong
	EPC belum login	Sistem mengarahkan EPC ke halaman login

3.2.25 Activity Diagram


Activity Diagram menggambarkan alur aktivitas yang terjadi antara aktor (**EPC**) dan sistem dalam setiap use case yang telah didefinisikan. Diagram ini menggunakan dua *swimlane* — EPC dan Sistem — untuk memperlihatkan tanggung jawab masing-masing pihak pada setiap tahap proses, termasuk titik keputusan (*decision point*) dan jalur alternatif yang mungkin terjadi.




Gambar 3.3. Activity Diagram Login




Gambar 3.4. Activity Diagram Register




Gambar 3.5. Activity Diagram Import Data Mahasiswa




Gambar 3.6. Activity Diagram Kelola Data Faculty Supervisor




Gambar 3.7. Activity Diagram Kelola Keywords Supervisor



Gambar 3.8. Activity Diagram Trigger Proses Rekomendasi




Gambar 3.9. Activity Diagram Lihat Hasil Rekomendasi




Gambar 3.10. Activity Diagram Export Hasil ke Excel

3.2.26 Class diagram


Class diagram disusun untuk merepresentasikan struktur kelas dan hubungan antar komponen utama dalam sistem rekomendasi. Diagram ini menggambarkan bagaimana setiap entitas pada sistem direpresentasikan, beserta atribut dan operasi yang mendukung proses pembentukan embedding, perhitungan scoring, alokasi menggunakan greedy solver, serta evaluasi hasil rekomendasi.



Gambar 3.13. Class Diagram: Service Architecture




Gambar 3.11. Class Diagram: ORM Models (id = PK, *id* = FK)



Gambar 3.12. Class Diagram: Runtime Dataclasses

3.2.27 Entity Relationship Diagram

Entity Relationship Diagram (ERD) digunakan untuk memodelkan struktur data dan hubungan antar entitas yang disimpan dalam basis data SQLite. ERD ini merepresentasikan lima entitas utama yang diperlukan dalam proses scoring, alokasi greedy, dan evaluasi hasil rekomendasi.



Gambar 3.14. Entity Relationship Diagram (id = PK, *italic* = FK)

3.2.28 Tahapan Implementasi

Tahapan implementasi merupakan tahap realisasi dari hasil analisis dan perancangan sistem yang telah dijelaskan pada sub-bab sebelumnya. Pada tahap ini, seluruh rancangan sistem yang telah dibuat diimplementasikan ke dalam bentuk sistem yang dapat dijalankan dan diuji secara fungsional. Proses implementasi dilakukan dengan mengacu pada metodologi waterfall, di mana setiap tahap dilaksanakan secara berurutan dan sistematis.

Implementasi pada penelitian ini mencakup implementasi pengolahan data, penerapan metode semantic similarity dan aturan pendukung yang berlaku, serta pe-

ngembangan dan deployment prototipe sistem rekomendasi faculty supervisor Program Enrichment.

3.2.29 Implementasi Pengolahan Data

Tahap awal implementasi sistem adalah pengolahan data. Data yang digunakan dalam penelitian ini berupa data tekstual yang berasal dari profil mahasiswa Program Enrichment dan data bidang keahlian faculty supervisor. Data tersebut dikumpulkan dari sumber institusional dan dokumen pemetaan historis yang telah digunakan sebelumnya.

Sebelum digunakan dalam sistem rekomendasi, data terlebih dahulu dipersiapkan agar memiliki format yang konsisten dan dapat diproses secara komputasional. Proses pengolahan data ini bertujuan untuk memastikan bahwa data yang digunakan memiliki kualitas yang baik dan sesuai dengan kebutuhan sistem.

3.2.30 Implementasi Praproses Data

Setelah data terkumpul, tahap selanjutnya adalah implementasi praproses data. Praproses data dilakukan untuk membersihkan dan menormalkan data tekstual sebelum dilakukan perhitungan kemiripan semantik.

Tahapan praproses data yang diimplementasikan meliputi:

1. Data cleansing, yaitu penghapusan data yang tidak relevan atau tidak diperlukan.
2. Case folding, untuk mengubah seluruh teks menjadi huruf kecil agar konsisten.
3. Tokenisasi, yaitu memecah teks menjadi unit kata.
4. Penghapusan stopwords, untuk menghilangkan kata-kata umum yang tidak memiliki kontribusi makna yang signifikan.

Normalisasi teks, agar data siap digunakan pada tahap representasi teks.

Tahapan ini bertujuan untuk mengurangi noise pada data dan meningkatkan akurasi sistem rekomendasi.

3.2.31 Implementasi Representasi Teks

Pada tahap ini, data tekstual yang telah melalui proses praproses diubah ke dalam bentuk representasi numerik. Representasi teks merupakan langkah penting karena sistem rekomendasi membutuhkan data dalam bentuk numerik untuk melakukan perhitungan kemiripan.

Representasi teks dilakukan dengan pendekatan semantic similarity, di mana teks profil mahasiswa dan bidang keahlian dosen direpresentasikan dalam bentuk vektor. Representasi ini memungkinkan sistem untuk memahami konteks dan makna teks secara lebih mendalam dibandingkan pendekatan berbasis pencocokan kata kunci.

Hasil dari tahap ini berupa vektor teks yang digunakan sebagai input utama pada proses perhitungan kemiripan semantik.

3.2.32 Implementasi Perhitungan Semantic Similarity

Setelah representasi teks diperoleh, tahap selanjutnya adalah implementasi perhitungan semantic similarity. Perhitungan dilakukan dengan membandingkan vektor representasi teks mahasiswa dengan vektor representasi teks faculty supervisor.

Nilai similarity yang dihasilkan menunjukkan tingkat kesesuaian antara topik atau minat mahasiswa dengan bidang keahlian dosen pembimbing. Nilai ini berada dalam rentang tertentu, di mana nilai yang lebih tinggi menunjukkan tingkat kesesuaian yang lebih baik.

Proses perhitungan similarity dilakukan untuk setiap pasangan mahasiswa dan faculty supervisor, sehingga sistem mampu menghasilkan daftar faculty supervisor yang diurutkan berdasarkan tingkat kecocokan. Hasil perhitungan ini kemudian disimpan dan digunakan pada tahap rekomendasi.

3.2.33 Implementasi Sistem Rekomendasi

Pada tahap ini, seluruh komponen sistem yang telah diimplementasikan sebelumnya diintegrasikan menjadi satu sistem rekomendasi yang utuh. Sistem rekomendasi dirancang untuk menghasilkan daftar rekomendasi faculty supervisor bagi

setiap mahasiswa berdasarkan hasil perhitungan similarity dan penerapan aturan yang berlaku.

Hasil rekomendasi ditampilkan dalam bentuk peringkat (ranking), di mana faculty supervisor dengan tingkat kesesuaian tertinggi berada pada urutan teratas. Sistem ini berfungsi sebagai decision support system, sehingga rekomendasi yang dihasilkan digunakan sebagai bahan pertimbangan oleh Enrichment Program Coordinator (EPC) dalam menentukan dosen pembimbing yang paling sesuai.

3.2.34 Implementasi dan Deployment Sistem

Tahap akhir dalam implementasi adalah pengembangan dan deployment prototipe sistem. Prototipe sistem dikembangkan dalam bentuk aplikasi berbasis web yang terdiri dari antarmuka pengguna dan backend untuk memproses data dan menghasilkan rekomendasi.

Prototipe ini memungkinkan pengguna untuk:

1. Mengakses data mahasiswa dan faculty supervisor.
2. Menjalankan proses rekomendasi secara otomatis.
3. Melihat hasil rekomendasi faculty supervisor berdasarkan tingkat kesesuaian.
4. Menggunakan sistem sebagai alat bantu dalam proses pemetaan faculty supervisor.

Deployment dilakukan untuk memastikan bahwa sistem dapat berjalan secara operasional dan siap digunakan sebagai pendukung proses pemetaan faculty supervisor Program Enrichment di Universitas XYZ

BAB IV

HASIL DAN PEMBAHASAN

4.1 Testing Environment

Dalam penelitian ini, penulis menggunakan bahasa pemrograman Python untuk membangun dan mengimplementasikan sistem rekomendasi Faculty Supervisor berbasis semantic similarity. Penulis juga menggunakan perangkat keras dan lunak tertentu untuk mengembangkan sistem tersebut. Berikut adalah daftar perangkat keras yang digunakan dalam penelitian ini.

Komponen	Spesifikasi
Processor	Apple M4 Pro (12-core CPU)
RAM	24 GB Unified Memory
GPU	Apple M4 Pro Integrated GPU (20-core) + Apple Neural Engine (16-core)
Disk Space	1 TB SSD

Tabel 4.1. Spesifikasi Perangkat Keras

Perangkat keras tersebut juga menggunakan beberapa perangkat lunak untuk proses pengembangan sistem rekomendasi Faculty Supervisor. Spesifikasi perangkat lunak yang digunakan adalah sebagai berikut.

Komponen	Spesifikasi
Sistem Operasi	macOS Sequoia 15
Bahasa Pemrograman	Python 3.12
Web Framework	Flask 3.1.0
ORM ; Database	SQLAlchemy 2.0.49 + SQLite
Embedding Library	sentence-transformers
Model Kandidat	BAAI/bge-m3, Qwen/Qwen3-Embedding-0.6B, intfloat/multilingual-e5-large-instruct
Data Processing	pandas, numpy, openpyxl
IDE	Visual Studio Code

Tabel 4.2. Spesifikasi Perangkat Lunak

4.2 Hasil

4.2.1 Evaluasi Model

Pada tahap ini dilakukan evaluasi terhadap tiga model *embedding* yang menjadi kandidat untuk komponen perhitungan kemiripan semantik. Secara keseluruhan, evaluasi mencakup **18 eksperimen** yang merupakan kombinasi dari 3 model, 3 konfigurasi *toggle* (*extra_docs* dan *group_bonus*), dan 2 varian kapasitas. Untuk perbandingan model yang adil, Tabel 4.3 menyajikan hasil pada konfigurasi yang identik (*extra_docs*=True, *group_bonus*=False) sehingga satu-satunya variabel yang berbeda adalah model *embedding*. Analisis pengaruh parameter konfigurasi

disajikan pada subbab berikutnya. Untuk memastikan keterulangan (*reproducibility*), seluruh proses dibuat deterministik sehingga eksekusi berulang menghasilkan keluaran yang identik.

Evaluasi dilakukan terhadap **168 dari 171 mahasiswa**. Sebanyak 3 mahasiswa dikecualikan karena tidak memiliki nilai `current_supervisor_code` yang valid sebagai *ground truth*.

Pengukuran dilakukan pada dua tingkat yang saling melengkapi:

- **Metrik *retrieval* (sebelum *solver*):** MRR, Hit@1, Hit@5, NDCG@5, NDCG@10, dan rata-rata peringkat (*avg_rank*). Metrik ini mengukur kualitas pemeringkatan dosen pembimbing sebelum proses alokasi kapasitas dijalankan.
- **Metrik *assignment* (setelah *solver*):** *Assignment Match Rate*. Metrik ini mengukur kesesuaian hasil penugasan akhir terhadap penugasan historis admin.

Hasil evaluasi seluruh model kandidat disajikan pada Tabel 4.3.

Model	MRR	Hit@1	Hit@5	NDCG@5	NDCG@10	Avg Rank	Match Rate
BAAI/bge-m3 (Run 8)	0,585	0,417	0,798	0,620	0,668	3,33	0,357
Qwen/Qwen3-Embedding-0.6B (Run 14)	0,478	0,298	0,750	0,523	0,580	4,14	0,423
intfloat/multilingual-e5-large-instruct (Run 20)	0,469	0,304	0,649	0,483	0,563	4,60	0,399
<i>Random baseline</i>	~0,23	~0,07	~0,36	~0,21	—	~7,5	—

Tabel 4.3. Perbandingan Metrik Evaluasi Antar Model

Secara deskriptif, **BAAI/bge-m3** memperoleh MRR tertinggi sebesar 0,585 dengan dosen pembimbing sebenarnya berada pada peringkat rata-rata 3,33. **Qwen/Qwen3-Embedding-0.6B** memperoleh MRR 0,478 dengan rata-rata peringkat 4,14, namun memiliki *Assignment Match Rate* tertinggi sebesar 0,423. **intfloat/multilingual-e5-large-instruct** memperoleh MRR 0,469 dengan rata-rata peringkat 4,60 dan *match rate* 0,399. Seluruh model berada jauh di atas *random*

baseline, yang menunjukkan bahwa pendekatan kemiripan semantik memberikan sinyal pencocokan yang nyata.

Untuk keperluan analisis lebih lanjut, nilai rata-rata skor kemiripan disajikan pada Tabel 4.4.

Model	Avg Similarity @1	Avg True Similarity	Selisih (sebaran)
BAAI/bge-m3 (Run 8)	0,617	0,585	0,032
Qwen/Qwen3-Embedding-0.6B (Run 14)	0,689	0,621	0,068
intfloat/multilingual-e5-large-instruct (Run 20)	0,870	0,853	0,017

Tabel 4.4. Rata-rata Skor Kemiripan Antar Model

4.2.2 Hasil Analisis Model dan Pemilihan Model Akhir

Berdasarkan hasil pada Tabel 4.3, **BAAI/bge-m3** unggul pada seluruh metrik *retrieval*: MRR, Hit@1, Hit@5, NDCG@5, NDCG@10, dan rata-rata peringkat terbaik (3,33). Keunggulan ini konsisten di setiap metrik, bukan hanya pada satu indikator, sehingga menunjukkan kualitas pemeringkatan yang lebih baik secara menyeluruh.

Temuan yang menarik muncul pada **Qwen/Qwen3-Embedding-0.6B**. Model ini memiliki *Assignment Match Rate* tertinggi (0,423), meskipun metrik *retrieval*-nya berada di bawah **BAAI/bge-m3**. Inversi ini mengindikasikan bahwa distribusi skor qwen3 secara kebetulan lebih selaras dengan ketersediaan slot kapasitas aktual, sehingga alokasi akhir lebih sering cocok dengan penugasan historis. Sebaliknya, **BAAI/bge-m3** yang unggul pada *retrieval* justru memperoleh *match rate* terendah (0,357) karena model tersebut meranking supervisor yang “paling tepat” secara semantik, yang belum tentu identik dengan pilihan historis admin.

Temuan lain dapat diamati pada **intfloat/multilingual-e5-large-instruct** melalui Tabel 4.4: model ini menghasilkan skor kemiripan yang sangat tinggi namun nyaris seragam (rata-rata skor peringkat-1 sebesar 0,870 dan skor dosen sebenarnya

0,853, dengan sebaran hanya 0,017). Artinya, model ini menilai hampir seluruh pasangan mahasiswa–dosen sebagai “sangat mirip” sehingga kehilangan kemampuan untuk membedakan satu dosen dari dosen lainnya secara tajam.

Temuan-temuan ini menegaskan prinsip penting dalam pemilihan model: **sebuah sistem rekomendasi dinilai dari kualitas pemeringkatannya** — yaitu kemampuan menempatkan dosen yang tepat pada posisi teratas — sehingga metrik *retrieval* menjadi acuan utama. *Assignment Match Rate* merupakan metrik hasil akhir yang bersifat melengkapi, namun apabila digunakan sendirian dapat menyesatkan.

Dengan pertimbangan tersebut, **BAAI/bge-m3** dipilih sebagai model akhir yang digunakan dalam sistem. Pemilihan ini didasarkan pada keunggulan menyeluruh pada metrik *retrieval*, yang merupakan indikator paling representatif terhadap tujuan utama sistem, yaitu memberikan rekomendasi dosen pembimbing yang relevan. Selain itu, hasil model ini telah diverifikasi bersifat deterministik dan dapat direproduksi secara identik pada eksekusi berulang, sehingga angka yang dilaporkan dapat dipertanggungjawabkan.

4.2.3 Analisis Pengaruh Parameter Konfigurasi

Selain membandingkan ketiga model pada konfigurasi yang sama, penelitian ini mengevaluasi pengaruh dua parameter konfigurasi terhadap kualitas rekomendasi, yaitu `extra_docs` dan `group_bonus`, melalui 18 eksperimen yang mencakup seluruh kombinasi model, nilai parameter, dan pengaturan kapasitas.

4.2.3.1 Pengaruh Parameter `extra_docs`

Parameter `extra_docs` menentukan apakah teks tambahan dari profil dosen (deskripsi laboratorium, proyek aktif) diikutsertakan dalam representasi vektor supervisor. Tabel 4.5 menunjukkan pengaruhnya terhadap persentase mahasiswa yang mendapatkan supervisor rekomendasi pertama (*%Rank-1*).

Pengaruh `extra_docs` bersifat *model-dependent*. Pada **BAAI/bge-m3**, dokumen tambahan memperkaya profil supervisor yang sebelumnya tipis sehingga me-

Model	extra_docs= True	extra_docs= False	$\Delta\%$ Rank-1	Rekomendasi
BAAI/bge-m3	61,4%	53,8%	+7,6pp	Aktifkan
Qwen3-Embedding-0.6B	31,6%	33,9%	-2,3pp	Nonaktifkan
mE5-large-instruct	35,5%	52,0%	-16,5pp	Nonaktifkan

Tabel 4.5. Pengaruh Parameter `extra_docs` terhadap %Rank-1

meningkatkan kemampuan diskriminasi model sebesar 7,6 poin persentase. Sebaliknya, pada **mE5-large-instruct**, dokumen tambahan justru merusak ruang *embedding* yang telah terkalibrasi, menyebabkan penurunan tajam sebesar 16,5 poin persentase karena skor antar supervisor menjadi semakin seragam.

4.2.3.2 Pengaruh Parameter `group_bonus`

Parameter `group_bonus` menambahkan skor tambahan bagi pasangan mahasiswa yang berada dalam grup yang sama dan dialokasikan kepada supervisor yang sama. Tabel 4.6 menunjukkan pengaruhnya terhadap %Rank-1.

Model	group_bonus= False	group_bonus= True	$\Delta\%$ Rank-1
BAAI/bge-m3	61,4%	53,8%	-7,6pp
Qwen3-Embedding-0.6B	31,6%	33,9%	+2,3pp
mE5-large-instruct	35,5%	tidak aktif	tidak berlaku

Tabel 4.6. Pengaruh Parameter `group_bonus` terhadap %Rank-1

Secara keseluruhan, `group_bonus` bersifat netral hingga merugikan. Pada **BAAI/bge-m3**, parameter ini menurunkan %Rank-1 sebesar 7,6 poin persentase. Pada **mE5-large-instruct**, kondisi grup *overflow* tidak pernah terpenuhi dalam data ini sehingga parameter tidak memberikan efek apapun. Hanya pada **Qwen3-Embedding-0.6B** yang menunjukkan sedikit peningkatan, namun diikuti dengan peningkatan nilai *delta_mean* yang mengindikasikan *displacement* lebih besar dari peringkat optimal.

4.2.3.3 Konfigurasi Terbaik

Berdasarkan hasil evaluasi terhadap 18 eksperimen, konfigurasi terbaik yang dipilih adalah **BAAI/bge-m3** dengan `extra_docs=True` dan `group_bonus=False` (Run 8). Konfigurasi ini menghasilkan MRR tertinggi (0,585), Hit@5 tertinggi (0,798), dan persentase mahasiswa yang mendapat peringkat pertama tertinggi (61,4%). Tabel 4.7 merangkum metrik konfigurasi terbaik ini.

Metrik	Nilai
MRR	0,585
Hit@1	0,417
Hit@5	0,798
nDCG@10	0,668
%Rank-1	61,4%
%Top-3	74,9%
Rata-rata Peringkat	3,22

Tabel 4.7. Metrik Konfigurasi Terbaik (Run 8: bge-m3, extra_docs=True, group_bonus=False)

4.2.4 Distribusi Beban Pembimbing

Sistem rekomendasi ini menggunakan *greedy solver* untuk mengalokasikan mahasiswa ke dosen pembimbing dengan mempertimbangkan kapasitas maksimal tiap dosen. Untuk memastikan bahwa proses alokasi menghasilkan distribusi beban yang merata, dilakukan analisis terhadap distribusi penugasan pada seluruh 18 konfigurasi eksperimen.

Hasil analisis menunjukkan bahwa seluruh 18 konfigurasi menghasilkan distribusi yang **identik**, sebagaimana disajikan pada Tabel 4.8.

Statistik	Nilai
Minimum penugasan per pembimbing	12
Maksimum penugasan per pembimbing	13
Rata-rata penugasan	12,21
Standar deviasi	0,426
<i>Gini Coefficient</i>	0,0138
Pembimbing dengan 13 mahasiswa	3
Pembimbing dengan 12 mahasiswa	11

Tabel 4.8. Distribusi Beban Penugasan Pembimbing (identik pada seluruh 18 konfigurasi)

Nilai *Gini Coefficient* sebesar 0,0138 mendekati nol, menandakan distribusi yang hampir sempurna merata. Seluruh dosen mendapatkan antara 12 hingga 13 mahasiswa, dengan hanya 3 dari 14 dosen yang menerima satu mahasiswa tambahan. Temuan ini menunjukkan bahwa mekanisme penegakan kapasitas (*capacity enforcement*) mendominasi hasil alokasi, sehingga variasi model *embedding* dan parameter konfigurasi tidak berpengaruh terhadap keseimbangan beban. Parameter *capacity_priority_codes* hanya menentukan dosen mana yang mendapat alokasi ekstra, namun tidak mengubah tingkat keseimbangan secara keseluruhan.

4.2.5 Distribusi Peringkat Penugasan

Untuk memahami kualitas alokasi dari perspektif kepuasan mahasiswa, dilakukan analisis terhadap distribusi peringkat supervisor yang ditetapkan (*assigned rank*) secara terkumpul (*pooled*) dari seluruh 3.078 slot penugasan pada 18 konfigurasi. Tabel 4.9 menyajikan distribusi tersebut.

Peringkat Ditetapkan	Jumlah	Persentase
1	1.397	45,4%
2	342	11,1%
3	211	6,9%
4	291	9,5%
5	90	2,9%
6 ke atas	747	24,3%


Tabel 4.9. Distribusi Peringkat Penugasan (*Pooled*, 3.078 slot dari 18 konfigurasi)

Distribusi ini memperlihatkan pola bimodal: puncak kuat pada peringkat 1 (45,4%), penurunan pada peringkat 2–3, dan peningkatan kembali pada peringkat 4. Pola ini mencerminkan dinamika saturasi kapasitas — ketika supervisor pilihan pertama seorang mahasiswa sudah penuh, mahasiswa tersebut cenderung jatuh ke peringkat 4–6 alih-alih peringkat 2–3. Hal ini terjadi karena supervisor-supervisor dengan kemiripan semantik tertinggi sering kali memiliki kapasitas yang terisi bersamaan, sehingga pilihan alternatif terdekat sudah tidak tersedia.

4.2.6 Aplikasi Web

Sistem rekomendasi mahasiswa ini diimplementasikan dalam bentuk aplikasi berbasis web dengan antarmuka yang fungsional. Aplikasi ini dirancang untuk memfasilitasi Enrichment Program Coordinator dalam melakukan pemetaan (mapping) antara mahasiswa peserta program enrichment dengan faculty supervisor terkait.

4.2.6.1 Login Page



Gambar 4.1. Tampilan Halaman Login


Halaman login merupakan gerbang utama interaksi pengguna dengan sistem yang menyediakan formulir terstruktur untuk memasukkan data kredensial. Antarmuka (interface) ini mencakup kolom (field) username dan kata sandi yang telah didaftarkan oleh pengguna sebelumnya. Juga bila pengguna belum memiliki akun bisa mendaftarkan akun dengan memilih tombol registrasi.

4.2.6.2 Register Page

Gambar 4.2. Tampilan Halaman Register

Pada halaman ini pengguna dapat membuat akun dengan mengisi beberapa fields seperti nama lengkap, username, password dan konfirmasi password. Lalu proses dilanjutkan dengan memilih tombol registrasi setelah mengisi data dan akun akan otomatis dibuat.

4.2.6.3 Dashboard




Gambar 4.3. Tampilan Halaman Dashboard

Halaman dashboard menyajikan ringkasan data statistik utama, meliputi total mahasiswa dan dosen yang telah terdaftar di dalam sistem. Selain itu, pengguna dapat memantau akumulasi proses eksekusi (total runs), tingkat akurasi pada eksekusi terakhir, serta rincian hasil evaluasi yang telah diproses. Fitur pada halaman

ini juga memungkinkan pengguna untuk mengakses rincian run, dan inspect row, hingga melakukan ekspor data ke format Excel berdasarkan hasil eksekusi terbaru.


4.2.6.4 Data Center



Gambar 4.4. Tampilan Halaman Data Center

Halaman ini berfungsi sebagai pusat pengelolaan data masukan (dataset) serta pengendali eksekusi awal (pipeline trigger) sistem. Peran utamanya adalah melakukan proses ETL (Extract, Transform, Load) guna memastikan kesiapan data mahasiswa dan dosen pembimbing sebelum diproses oleh algoritma rekomendasi.

4.2.6.5 Run History




Gambar 4.5. Tampilan Halaman Run History

Halaman Run History menyajikan riwayat seluruh proses eksekusi run yang telah dilakukan oleh sistem. Informasi yang ditampilkan mencakup waktu eksekusi,

jumlah mahasiswa dan dosen yang terlibat, model yang digunakan, serta hasil evaluasinya. Selain itu, pengguna dapat melakukan aksi lanjutan untuk meninjau rincian eksekusi detail run maupun mengeksport data ke dalam format Excel.


4.2.6.6 Run Details



Gambar 4.6. Tampilan Halaman Run Details

Halaman Run Details menampilkan rincian hasil dari proses eksekusi run yang telah dilakukan. Informasi yang disajikan mencakup data spesifik untuk setiap mahasiswa, meliputi NIM, Nama, Track, Partner, Topik, Current Supervisor, Recommended Supervisor, Final Score, dan Rule Match. Selain itu, pengguna dapat menggunakan fitur filter untuk mempermudah pencarian data berdasarkan parameter tertentu, seperti nama, topik, maupun dosen supervisor tertentu. .


4.2.6.7 Supervisor Studio



Gambar 4.7. Tampilan Halaman Supervisor Studio

Halaman Supervisor Studio berfungsi mengelola repositori dosen pembimbing dan semantic keywords. Fitur utama halaman ini meliputi searchable dropdown dan tombol Load Supervisor untuk pemanggilan profil dosen, serta Export Config Excel untuk pencadangan data. Selain itu, terdapat formulir Add Supervisor untuk perekaman data dosen baru, panel Keywords Studio untuk memanipulasi komponen chip kata kunci secara dinamis, dan Supervisor Table yang menyajikan akumulasi data dosen terdaftar secara terstruktur.

4.2.6.8 Rules Studio



Gambar 4.8. Tampilan Halaman Rules Studio

Halaman Rules Studio berfungsi mengonfigurasi parameter klasifikasi label semantik yang digunakan dalam proses rekomendasi. Fitur utama meliputi pengaturan *cosine similarity threshold* per label semantik, pengelolaan deskripsi label yang menentukan pemetaan profil mahasiswa ke kategori penugasan tertentu (seperti `apple_mobile` atau `binus_bandung`), serta pratinjau skor label untuk profil mahasiswa tertentu. Perubahan konfigurasi pada halaman ini akan berpengaruh pada proses deteksi label pada *pipeline* run berikutnya.

4.3 Evaluasi

Pengujian Black Box dilakukan untuk memvalidasi fungsionalitas sistem dari sudut pandang pengguna tanpa melihat struktur kode internal. Fokus pengujian ini adalah memastikan bahwa setiap input memberikan output yang sesuai dengan spesifikasi kebutuhan sistem. Metode yang digunakan adalah Equivalence Partitioning,

di mana data uji dibagi ke dalam beberapa kategori untuk menguji perilaku sistem terhadap input yang valid dan tidak valid.

4.3.1 Login Page

Pada halaman ini terdapat tombol “Login” yang akan mengarahkan pengguna jika mengisi kredensial dengan benar.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Login dengan kredensial valid	Username dan kata sandi benar	Sistem mengarahkan pengguna ke dashboard	Pass
2	Login dengan kata sandi salah	Username benar, kata sandi salah	Sistem menampilkan message “Kredensial Salah”	Pass
3	Login dengan username salah	Username salah, kata sandi benar	Sistem menampilkan message “Kredensial Salah”	Pass

Tabel 4.10. Skenario Login Page

4.3.2 Register Page

Pada halaman ini pengguna dapat membuat akun dengan mengisi data email dan password sebagai kredensial.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Mendaftarkan akun dengan data valid	Username, nama lengkap, password, dan konfirmasi password benar	Sistem menyimpan akun dan mengarahkan pengguna ke dashboard	Pass
2	Mendaftarkan akun dengan password tidak cocok	Password dan konfirmasi password berbeda	Sistem menampilkan message “Data tidak sesuai”	Pass
3	Mendaftarkan akun dengan username yang sudah terdaftar	Username yang sudah digunakan akun lain	Sistem menampilkan message “Data tidak sesuai”	Pass

Tabel 4.11. Skenario Register Page

4.3.3 Dashboard

Pada halaman ini bertujuan pada fungsionalitas visual dan interaksi pada halaman Dashboard. Pengujian mencakup validasi tampilan data statistik, grafik tren, detail eksekusi terbaru, dan kontrol navigasi.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Klik Menu "Dashboard"	-	Sistem mengarahkan pengguna ke halaman Data Center	Pass
2	Klik menu "Run History"	-	Sistem mengarahkan pengguna ke halaman Run History	Pass
3	Klik menu "Supervisor Studio"	-	Sistem mengarahkan pengguna ke halaman Supervisor Studio	Pass
4	Klik menu "Rules Studio"	-	Sistem mengarahkan pengguna ke halaman Rules Studio	Pass
5	Klik tombol "Generate New Run"	-	Sistem akan mengarahkan pengguna ke tampilan untuk melakukan run baru	Pass
6	Klik tombol "Open Detail"	-	Sistem mengarahkan pengguna ke halaman detail dari run terakhir	Pass
7	Klik tombol "Inspect Rows"	-	Sistem akan mengarahkan pengguna melihat data pada Run History	Pass
8	Klik tombol "Export Excel"	-	Sistem akan melakukan export pada data run terakhir.	Pass
9	Sistem menampilkan data pada Summary Cards	-	Data yang ditampilkan sesuai dengan database	Pass
10	Sistem menampilkan data pada Quality Trend	-	Sistem menampilkan toloptop detail nilai Match Rate, Hybrid MRR, dan Content MRR	Pass
11	Sistem menampilkan Informasi Snapshot	-	Sistem menampilkan data dari run paling baru	Pass

Tabel 4.12. Skenario Dashboard

4.3.4 Data Center

Pada halaman ini pengujian bertujuan untuk memvalidasi fungsi manajemen import data serta interaksi pipeline trigger. Halaman ini krusial karena bertindak sebagai penyedia data utama sebelum sistem menjalankan algoritma rekomendasi.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Upload Data Kosong	-	Sistem menolak proses import dan menampilkan error message	Pass
2	Upload Data dengan Format Salah	-	Sistem menolak proses import dan menampilkan error message	Pass
3	Upload Valid	-	File berhasil disimpan, dan sistem akan menampilkan data pada summary cards.	Pass
4	Data pada Summary Cards sesuai	-	Data yang ditampilkan sesuai dengan data upload	Pass
5	Klik tombol “Generate New Run”	-	Sistem akan mengarahkan pengguna ke tampilan untuk melakukan run baru	Pass

Tabel 4.13. Skenario Data Center

4.3.5 Generate New Run

Pada halaman ini pengujian berfungsi untuk melakukan pengecekan ketika pengguna ingin melakukan run baru dengan memilih model dan rules boost yang akan diterapkan pada run tersebut.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Memilih Model	-	Model yang dipilih akan terlihat dengan ditandai berwarna oren	Pass
2	Mengaktifkan Group Bonus	-	Toggle group bonus yang dipilih akan berubah warna menjadi oren	Pass
3	Menonaktifkan Group Bonus	-	Toggle group bonus kembali ke kondisi nonaktif	Pass
4	Cancel Run	-	Sistem akan menutup pop-up new run	Pass
5	Eksekusi Run Baru	-	Sistem akan menjalankan rekomendasi dengan model dan rules yang dipilih	Pass

Tabel 4.14. Skenario Generate New Run

4.3.6 Run History

Pada halaman ini bertujuan untuk memastikan sistem mampu menyajikan daftar riwayat run algoritma secara kronologis dan akurat. Fokus utama meliputi kebenaran metadata yang ditampilkan serta fungsionalitas button.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Sistem menampilkan tabel riwayat run yang sudah dijalankan	-	Sistem menampilkan kolom Run ID, Created, Students, Supervisor, Model, Solver, Objective, Match Rate, dan Hybrid MRR	Pass
2	Tabel Riwayat di Tampilkan Berdasarkan Urutan Terakhir Dijalankan	-	Data ditampilkan secaraurut (Descending)	Pass
3	Klik tombol “Details Row” pada salah satu ID Run	-	Sistem berpindah ke halaman detail page dari run yang dipilih	Pass
4	Klik tombol “Export Data’ pada salah satu ID Run	-	Sistem melakukan export data sesuai ID Run yang dipilih	Pass
5	Klik tombol “ Generate New Run pada page Run History	-	Sistem mengarahkan pengguna ke halaman pembuatan run baru	Pass

Tabel 4.15. Skenario Run History

4.3.7 Supervisor Studio

Pada halaman ini bertujuan untuk memastikan sistem memvalidasi fitur pengelolaan data dosen pembimbing beserta kata kunci semantik.

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Membuka menu dropdo- wn dan mencari berda- sarkan nama atau kode dosen	-	Sistem menyaring data secara dinamis berdasark- an data dosen yang dicari	Pass
2	Memilih salah satu nama dosen kemudian menek- an tombol “Load Supervi- sor”	-	Sistem menampilkan pro- fil dosen dan keyword yang sesuai dengan dosen tersebut	Pass
3	Menekan tombol “Export Config”	-	Sistem akan mengunduh berkas excel berisikan da- ta dosen dan profilnya.	Pass
4	Mengetikkan keyword baru pada kolom “Add Keyword”	-	Keyword di daftarkan di dalam daftar keyword	Pass
5	Menekan tombol (X) pa- da salah satu komponen chip	-	Chip keyword akan diha- puskan	Pass
6	Menekan tombol “Save Keywords” setelah mela- kukan perubahan chip	-	Sistem memperbarui daf- tar keyword semantik pa- da dosen di database	Pass

Tabel 4.16. Skenario Supervisor Studio

4.3.8 Rules Studio

Pada halaman ini testing bertujuan untuk memvalidasi fleksibilitas pengaturan rules. Halaman ini mengontrol cosine similarity threshold dan deskripsi label semantik yang menentukan bagaimana profil minat mahasiswa dipetakan ke dalam kategori penugasan tertentu (seperti apple_mobile atau binus_bandung).

No	Skenario Pengujian	Data Uji	Hasil yang Diharapkan	Status
1	Mengubah nilai <i>threshold cosine similarity</i> pada salah satu label semantik	Nilai <i>threshold</i> yang valid (0–1)	Nilai <i>threshold</i> tersimpan dan akan diterapkan pada run berikutnya	Pass
2	Memasukkan nilai <i>threshold</i> yang tidak valid	Nilai negatif atau lebih dari 1	Sistem menampilkan pesan <i>error</i> dan menolak perubahan	Pass
3	Memperbarui deskripsi label semantik	Deskripsi label baru yang valid	Deskripsi label berhasil diperbarui di database	Pass
4	Menekan tombol “Preview Score” untuk profil mahasiswa tertentu	-	Sistem menampilkan skor per label untuk profil yang dipilih	Pass
5	Menyimpan perubahan konfigurasi <i>rules</i>	-	Sistem memperbarui konfigurasi dan menampilkan konfirmasi keberhasilan	Pass
6	Navigasi kembali ke halaman Dashboard	-	Sistem mengarahkan pengguna ke halaman Dashboard	Pass

Tabel 4.17. Skenario Rules Studio

BAB V

SIMPULAN DAN SARAN

5.1 Simpulan

Penelitian ini bertujuan untuk mengembangkan sistem rekomendasi *Faculty Supervisor* berbasis *semantic similarity* sebagai pendukung keputusan dalam proses pemetaan mahasiswa peserta Program Enrichment di XYZ University. Berdasarkan hasil analisis, perancangan, implementasi, dan evaluasi yang telah dilakukan, dapat ditarik simpulan sebagai berikut.

1. Proses pemetaan *Faculty Supervisor* yang berjalan saat ini masih dilakukan secara manual oleh *Enrichment Program Coordinator* (EPC) menggunakan *spreadsheet*, memerlukan waktu satu hingga tiga minggu per periode, dan rentan terhadap inkonsistensi karena bergantung pada pengetahuan individual EPC. Tidak terdapat mekanisme yang terstruktur untuk mencocokkan minat mahasiswa dengan bidang keahlian dosen pembimbing, sehingga beban bimbingan cenderung tidak merata dan relevansi penugasan tidak dapat dijamin.
2. Sistem rekomendasi yang dikembangkan menggunakan pendekatan *scoring* yang menggabungkan dua komponen: (a) kemiripan semantik berbasis *text embedding* untuk merepresentasikan profil mahasiswa dan dosen secara numerik, dan (b) *company group bonus* untuk mendorong konsistensi penugasan mahasiswa dari perusahaan yang sama. Hasil *scoring* kemudian dialokasikan menggunakan *greedy solver* dengan mempertimbangkan batasan kapasitas dosen. Sistem diimplementasikan sebagai aplikasi berbasis web yang mencakup delapan halaman fungsional dan diuji menggunakan metode *black box* dengan pendekatan *equivalence partitioning* — seluruh skenario pengujian menghasilkan status *Pass*.
3. Evaluasi dilakukan terhadap 168 dari 171 mahasiswa menggunakan tiga model *embedding* kandidat. Model terbaik, yaitu **BAAI/bge-m3**, mencapai nilai

MRR sebesar 0,585, Hit@5 sebesar 0,804, dan rata-rata peringkat (*avg_rank*) 3,32 — jauh di atas *random baseline* (MRR $\sim$ 0,23). Hasil ini menunjukkan bahwa sistem mampu menempatkan dosen pembimbing yang relevan pada posisi peringkat atas secara konsisten. *Assignment Match Rate* sebesar 0,357 mengindikasikan tingkat keselarasan yang memadai antara rekomendasi sistem dengan data pemetaan historis yang dijadikan *ground truth*.

4. Sistem yang dikembangkan berpotensi meningkatkan efisiensi proses pemetaan melalui otomatisasi perhitungan kemiripan dan pembangkitan rekomendasi yang sebelumnya dilakukan secara manual. Dengan antarmuka yang dapat dioperasikan langsung oleh EPC, sistem ini mendukung transparansi dan konsistensi proses pemetaan tanpa menghilangkan otoritas keputusan akhir dari koordinator program.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran untuk pengembangan lebih lanjut:

1. **Perluasan cakupan data supervisor.** Representasi dosen pembimbing saat ini bergantung pada data historis bimbingan dan rekomendasi topik skripsi yang tersedia. Penambahan sumber data seperti publikasi ilmiah, profil penelitian, atau portofolio proyek dosen dapat memperkaya representasi semantik dan meningkatkan kualitas rekomendasi.
2. **Perluasan cakupan program enrichment.** Sistem yang dikembangkan saat ini difokuskan pada jalur magang (*internship*). Pengembangan selanjutnya dapat mencakup jalur lain dalam Program Enrichment, seperti penelitian (*research*), kewirausahaan (*entrepreneurship*), dan pengembangan profesional, dengan penyesuaian pada skema representasi data mahasiswa.
3. ***Fine-tuning* model *embedding* pada domain akademik Indonesia.** Model *embedding* yang digunakan merupakan model *pre-trained* bersifat umum. Melakukan *fine-tuning* pada korpus akademik berbahasa Indonesia atau data

spesifik domain Program Enrichment berpotensi meningkatkan akurasi pencocokan semantik secara signifikan.

4. **Evaluasi usability dengan pengguna nyata.** Pengujian yang dilakukan dalam penelitian ini terbatas pada *black box testing* fungsional. Evaluasi lanjutan menggunakan *System Usability Scale* (SUS) dengan melibatkan EPC sebagai pengguna nyata perlu dilakukan untuk mengukur tingkat penerimaan dan kemudahan penggunaan sistem secara empiris.
5. **Integrasi dengan sistem informasi akademik institusi.** Saat ini sistem memerlukan unggah data manual dalam format Excel. Integrasi langsung dengan sistem informasi akademik XYZ University akan mengurangi potensi kesalahan input data dan mempersingkat alur kerja EPC secara keseluruhan.
6. **Studi longitudinal terhadap kualitas rekomendasi.** Evaluasi dalam penelitian ini menggunakan data historis satu tahun sebagai *ground truth*. Studi lanjutan yang mengikuti keluaran rekomendasi selama beberapa periode pemetaan akan memberikan gambaran yang lebih representatif terhadap kualitas sistem dalam kondisi operasional nyata.

DAFTAR PUSTAKA

- BINUS University. (2025). *Kenali 7 Enrichment Track di BINUS University!* Retrieved from <https://binus.ac.id/kemanggisan/2025/09/19/kenali-7-enrichment-track-di-binus-university/> (Diakses pada 13 Juni 2026)
- Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T. (2017). Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5, 135–146. doi: 10.1162/tacl_a.00051
- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). M3-embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. In *Findings of the association for computational linguistics: ACL 2024* (pp. 2318–2335). Association for Computational Linguistics. doi: 10.18653/v1/2024.findings-acl.137
- Cohan, A., Feldman, S., Beltagy, I., Downey, D., & Weld, D. S. (2020). SPECTER: Document-level representation learning using citation-informed transformers. In *Proceedings of the 58th annual meeting of the association for computational linguistics* (pp. 2270–2282). Association for Computational Linguistics. Retrieved from <https://aclanthology.org/2020.acl-main.207> doi: 10.18653/v1/2020.acl-main.207
- Copeland, R. (2008). *Essential SQLAlchemy*. Sebastopol, CA: O'Reilly Media.
- Dasri, D., Annisa, A., & Haryanto, T. (2025). Two-way thesis supervisor recommendation system using MapReduce K-Skyband view queries. *JOIV: International Journal on Informatics Visualization*, 9(1), 163–175. Retrieved from <https://joiv.org/index.php/joiv/article/view/2800> doi: 10.62527/joiv.9.1.2800
- Dennis, A., Wixom, B. H., & Roth, R. M. (2020). *Systems analysis and design* (7th ed.). Hoboken, NJ: Wiley.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of

- deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the north American chapter of the association for computational linguistics: Human language technologies* (pp. 4171–4186). Association for Computational Linguistics. doi: 10.18653/v1/N19-1423
- Evangelista, A., Fan, Y., & Harb, H. (2021). An automated thesis supervisor allocation process using machine learning. *Global Journal of Engineering Education*, 23(1). Retrieved from <http://www.wiete.com.au/journals/GJEE/Publish/vol23no1/03-Evangelista-A.pdf>
- Flanagan, D. (2020). *JavaScript: The definitive guide* (7th ed.). Sebastopol, CA: O'Reilly Media.
- Grinberg, M. (2018). *Flask web development: Developing web applications with Python* (2nd ed.). Sebastopol, CA: O'Reilly Media.
- Gündoğan, E., Kaya, M., & Daud, A. (2023). Deep learning for journal recommendation system of research papers. *Scientometrics*, 128(1), 461–481. Retrieved from <https://doi.org/10.1007/s11192-022-04535-y> doi: 10.1007/s11192-022-04535-y
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Waltham, MA: Morgan Kaufmann.
- Herlocker, J. L., Konstan, J. A., Terveen, L. G., & Riedl, J. T. (2004). Evaluating collaborative filtering recommender systems. *ACM Transactions on Information Systems*, 22(1), 5–53. doi: 10.1145/963770.963772
- Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing* (3rd ed.). Pearson. Retrieved from <https://web.stanford.edu/~jurafsky/slp3/> (3rd edition draft)
- Kurose, J. F., & Ross, K. W. (2017). *Computer networking: A top-down approach* (7th ed.). Hoboken, NJ: Pearson.
- LeCun, Y., Bengio, Y., & Hinton, G. E. (2015). Deep learning. *Nature*, 521(7553), 436–444. doi: 10.1038/nature14539
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge, UK: Cambridge University Press. Retrieved from <https://nlp.stanford.edu/IR-book/>

- Mell, P., & Grance, T. (2011). *The NIST definition of cloud computing* (NIST Special Publication No. 800-145). Gaithersburg, MD: National Institute of Standards and Technology. Retrieved from <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-145.pdf> doi: 10.6028/NIST.SP.800-145
- Mihalcea, R., Corley, C., & Strapparava, C. (2006). Corpus-based and knowledge-based measures of text semantic similarity. In *Proceedings of the 21st national conference on artificial intelligence (aaai-06)* (Vol. 6, pp. 775–780). Boston, MA: AAAI Press. Retrieved from <https://aaai.org/papers/00775-aaai06-123-corpus-based-and-knowledge-based-measures-of-text-semantic-similarity/>
- Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems* (Vol. 26). Curran Associates, Inc.
- Mitchell, T. M. (1997). *Machine learning*. New York: McGraw-Hill.
- Nagarajan, S., Thangaraj, H., Vashisht, V., Joshi, E., Verma, K., & Katariya, D. (2025). A BERT based hybrid recommendation system for academic collaboration. In *Proceedings of the international conference on intelligent systems and security (ICISS 2024)* (pp. 111–125). Springer Nature Singapore. doi: 10.1007/978-981-96-4273-1_9
- Owens, M. (2006). *The definitive guide to SQLite*. Berkeley, CA: Apress.
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. In *Advances in neural information processing systems* (Vol. 32). Curran Associates, Inc.
- Pennington, J., Socher, R., & Manning, C. D. (2014). GloVe: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (emnlp)* (pp. 1532–1543). Association for Computational Linguistics. doi: 10.3115/v1/d14-1162
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 conference on empiri-*

- cal methods in natural language processing (emnlp-ijcnlp)* (pp. 3980–3990). Association for Computational Linguistics. doi: 10.18653/v1/d19-1410
- Ricci, F., Rokach, L., & Shapira, B. (Eds.). (2015). *Recommender systems handbook* (2nd ed.). Boston, MA: Springer. doi: 10.1007/978-1-4899-7637-6
- Rismanto, R., Syulistyo, A. R., & Agusta, B. P. C. (2020). Research supervisor recommendation system based on topic conformity. *International Journal of Modern Education and Computer Science*, 12(1), 26–34. doi: 10.5815/ijmecs.2020.01.04
- Rosenberger, J., Wolfrum, L., Weinzierl, S., Kraus, M., & Zschech, P. (2025). CareerBERT: Matching resumes to ESCO jobs in a shared embedding space for generic job recommendations. *Expert Systems with Applications*, 275, 127043. Retrieved from <https://doi.org/10.1016/j.eswa.2025.127043> doi: 10.1016/j.eswa.2025.127043
- Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Hoboken, NJ: Pearson.
- Sabilillah, F. T., Winarno, S., & Abiyyi, R. B. (2024). Implementasi BERT dan cosine similarity untuk rekomendasi dosen pembimbing berdasarkan judul tugas akhir. *Edumatic: Jurnal Pendidikan Informatika*, 8(2), 585–594. Retrieved from <https://e-journal.hamzanwadi.ac.id/index.php/edumatic/article/view/27791> doi: 10.29408/edumatic.v8i2.27791
- Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. doi: 10.1016/0306-4573(88)90021-0
- Shani, G., & Gunawardana, A. (2011). Evaluating recommendation systems. In F. Ricci, L. Rokach, B. Shapira, & P. B. Kantor (Eds.), *Recommender systems handbook* (pp. 257–297). Boston, MA: Springer. doi: 10.1007/978-0-387-85820-3_8
- Van Rossum, G., & Drake, F. L. (2009). *Python 3 reference manual*. Scotts Valley, CA: CreateSpace.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ...

- Polosukhin, I. (2017). Attention is all you need. In *Advances in neural information processing systems* (Vol. 30). Curran Associates, Inc.
- Voorhees, E. M. (1999). The TREC-8 question answering track report. In E. M. Voorhees & D. K. Harman (Eds.), *Proceedings of the eighth text retrieval conference (TREC-8)* (Vol. 500-246). Gaithersburg, Maryland: National Institute of Standards and Technology (NIST). Retrieved from https://trec.nist.gov/pubs/trec8/papers/qa_report.pdf
- Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 text embeddings: A technical report*. doi: 10.48550/arxiv.2402.05672
- Wang, X., Zhou, J., Jian, L., Yin, Y., & Li, L. (2025). Empowering college students to select ideal advisors: A text-based recommendation model. *Frontiers in Education*, 10. Retrieved from <https://doi.org/10.3389/feduc.2025.1673956> doi: 10.3389/feduc.2025.1673956
- Zhang, M., Sun, J., Ma, J., Wu, T., & Liu, Z. (2016). A personality matching-aided approach for supervisor recommendation. In *2016 49th hawaii international conference on system sciences (hicss)* (pp. 678–687). doi: 10.1109/hicss.2016.90
- Zhang, Y., Li, M., Long, D., Zhang, X., Lin, H., Yang, B., ... Zhou, J. (2025). Qwen3 embedding: Advancing text embedding and reranking through foundation models. *arXiv preprint arXiv:2506.05176*. Retrieved from <https://arxiv.org/abs/2506.05176>

LAMPIRAN

Lampiran A: Jadwal Kegiatan dan Penelitian